Detekcia falošných online recenzií na základe jazykových a behaviorálnych príznakov*

Matvii Nosenko, Volodymyr Nedoluha, Danylo Nikolenko, Rostyslav Mykytiuk
Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií
xnosenko@stuba.sk, xnedoluha@stuba.sk, xnikolenkod@stuba.sk, xmykytiuk@stuba.sk

20. októbra 2026

Abstrakt

Online recenzie výrazne ovplyvňujú rozhodovanie spotrebiteľov, no ich dôveryhodnosť narúšajú falošné recenzie generované firmami, platenými recenzentmi či automatizovanými nástrojmi. Tento článok prináša prehľad súčasných metód detekcie falošných recenzií so zameraním na porovnanie jazykových (textových) a behaviorálnych (na správaní recenzenta založených) príznakov.

1 Úvod

Tento článok vznikol v rámci semestrálneho projektu v predmete Metódy inžinierskej práce na Fakulte informatiky a informačných technológií Slovenskej technickej univerzity v Bratislave (FIIT STU). Súčasný rozmach elektronického obchodu priniesol výrazný nárast vplyvu používateľských recenzií na spotrebiteľské správanie. Spotrebitelia sa pri nákupe tovarov a služieb spoliehajú na skúsenosti iných zákazníkov, čo vytvára motiváciu pre nekalé subjekty manipulovať trh falošnými hodnoteniami. Detekcia takýchto recenzií predstavuje dôležitú výzvu prepájajúcu spracovanie prirodzeného jazyka a analýzu používateľského správania.

*Semestrálny projekt v predmete Metódy inžinierskej práce, ak. rok 2026/27, vedenie: Meno Priezvisko

2 Súvisiace práce

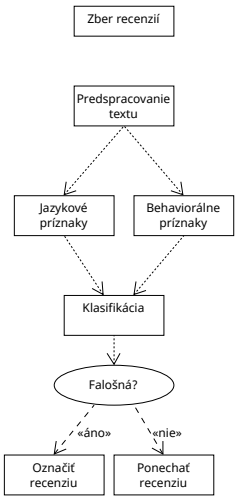
Priekopnícku prácu v oblasti odhaľovania falošných recenzií publikovali Jindal a Liu [1], ktorí kategorizovali recenzný spam a identifikovali duplicitné texty ako primárny indikátor manipulácie. Následne Ott a kol. [2] vytvorili prvý štandardizovaný zlatý dataset klamlivých recenzií (*deceptive opinion spam*) a ukázali, že metódy strojového učenia využívajúce n-gramy a psycholingvistické lexikóny dosahujú výrazne vyššiu úspešnosť než ľudskí posudzovatelia.

Ekonomické aspekty a motivácie komerčných subjektov analyzovali Luca a Zervas [3], pričom poukázali na to, že reštaurácie a podniky s horšou reputáciou majú signifikantne vyššiu tendenciu publikovať falošné pozitívne recenzie. Mukherjee a kol. [4] sa zamerali na reálny filtrovací mechanizmus platformy Yelp a ukázali, že na reálnych dátach dosahujú behaviorálne príznaky pri odhaľovaní falošných recenzií lepšie výsledky než samotné jazykové príznaky (n-gramy).

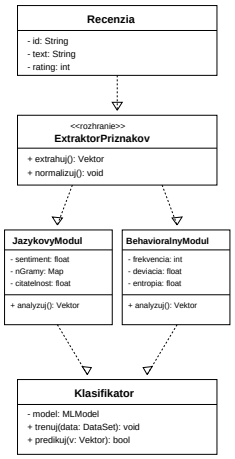
3 Jazykové príznaky

Jazykové príznaky vychádzajú z predpokladu, že autori vymyslených recenzií používajú odlišné štylistické a syntaktické vzory než reálni zákazníci. Medzi kľúčové metriky patrí:

- **Lexikálna bohatosť:** Pomer počtu unikátnych slov k celkovému počtu slov (Type-Token Ratio) býva pri falošných recenziách nižší v dôsledku obmedzenej slovnej zásoby.



Obr. 1: Proces detekcie recenzií



Obr. 2: Architektúra extrakcie príznakov

- **Distribúcia slovných druhov:** Ott a kol. [2] pozorovali, že klamlivé recenzie obsahujú pomerne viac slovies, príslovok a zámen, zatiaľ čo pravdivé recenzie viac podstatných a prídavných mien a predložiek.

- **Polarita a subjektivita:** Extrémne pozitívne alebo negatívne sentimenty s nízkou mierou vecnej argumentácie.

Na obr. 1 a 2 sú znázornené dva diagramy vytvorené v nástroji UMLet/UMLetino: vľavo proces detekcie falošných recenzií (obr. 1) a vpravo architektúra tried extraktora príznakov v UML notácii (obr. 2).

4 Behaviorálne príznaky

Behaviorálne príznaky charakterizujú aktivitu používateľov v čase a ich anomálie voči bežnému správaniu. Na reprezentáciu kombinácie jazykových a behaviorálnych metrík pre vzorky recenzií slúži matica príznakov $\mathbf{X}_{5\times 4}$ v rovnici (1), kde riadky zodpovedajú jednotlivým recenziám a stĺpce predstavujú ilustračné hodnoty sentimentu (v intervale $\langle -1, 1\rangle$), lexikálnej diverzity, frekvencie publikovania (počet recenzií za mesiac) a odchýlky hodnotenia od priemeru:

$$\mathbf{X}_{5\times 4} = \begin{pmatrix} 0.82 & 0.15 & 14.5 & 2.40 \\ -0.45 & 0.78 & 1.2 & 0.15 \\ 0.94 & 0.05 & 28.0 & 2.85 \\ 0.12 & 0.65 & 2.1 & 0.40 \\ -0.78 & 0.42 & 19.3 & 2.10 \end{pmatrix} \tag{1}$$

Pre modelovanie vývoja reputácie recenzenta u v čase po n publikovaných príspevkoch využívame postupnosť $R_n(u)$. Vzorec (2) vyjadruje výpočet tejto postupnosti s rozvojom, ktorý presahuje šírku riadku, preto je sadzaný pomocou viacriadkového prostredia `multline`:

$$\begin{aligned} R_n(u) &= R_0 + \sum_{k=1}^{n} \left(\alpha \cdot \frac{k^2 + 2k + 1}{k!} + \beta \cdot \lambda^{k-1} \right) \\ &= R_0 + \left(\alpha \frac{4}{1!} + \beta \right) + \left(\alpha \frac{9}{2!} + \beta\lambda \right) + \left(\alpha \frac{16}{3!} + \beta\lambda^2 \right) \\ &+ \left(\alpha \frac{25}{4!} + \beta\lambda^3 \right) + \cdots + \left(\alpha \frac{n^2 + 2n + 1}{n!} + \beta\lambda^{n-1} \right) \end{aligned} \tag{2}$$

5 Porovnanie prístupov

Čisto jazykové prístupy môžu byť menej spoľahlivé pri sofistikovaných textoch generovaných modernými veľkými jazykovými modelmi (LLM), zatiaľ čo behaviorálne analýzy sú voči štylistickým modifikáciám odolnejšie. Na druhej strane,

behaviorálne metriky vyžadujú dostatočnú históriu používateľského účtu, čo limituje ich použitie pri nových recenzentoch (problém studeného štartu). Preto sa ako perspektívny javí hybridný prístup kombinujúci obe skupiny príznakov.

6 Záver

V tejto predbežnej verzii článku sme predstavili štruktúru riešenia detekcie falošných recenzií so zameraním na synergiu textových a behaviorálnych atribútov. V nadväzujúcej fáze projektu sa zameriame na experimentálne vyhodnotenie klasifikátorov na reálnych dátach z portálov Yelp a Amazon a implementáciu hybridného modelu.

Literatúra

[1] Nitin Jindal and Bing Liu. Opinion spam and analysis. In *Proceedings of the 2008 International Conference on Web Search and Data Mining (WSDM)*, pages 219–230. ACM, 2008.

[2] Myle Ott, Yejin Choi, Claire Cardie, and Jeffrey T. Hancock. Finding deceptive opinion spam by any stretch of the imagination. In *Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics*, pages 309–319, 2011.

[3] Michael Luca and Georgios Zervas. Fake it till you make it: Reputation, competition, and Yelp review fraud. *Management Science*, 62(12):3412–3427, 2016.

[4] Arjun Mukherjee, Vivek Venkataraman, Bing Liu, and Natalie Glance. What Yelp fake review filter might be doing? In *Proceedings of the International AAAI Conference on Web and Social Media*, volume 7, pages 409–418, 2013.