Detekcia falošných online recenzií na základe jazykových a behaviorálnych príznakov*

Matvii Nosenko, Volodymyr Nedoluha
Danylo Nikolenko, Rostyslav Mykytiuk
Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií
xnosenko@stuba.sk, xnedoluha@stuba.sk
xnikolenkod@stuba.sk, xmykytiuk@stuba.sk

1. novembra 2026

Abstrakt

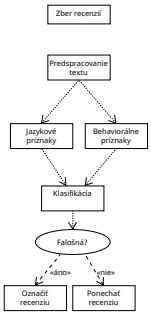
Online recenzie výrazne ovplyvňujú rozhodovanie spotrebiteľov, no ich dôveryhodnosť narúšajú falošné recenzie vytvárané firmami, platenými recenzentmi, konkurenciou či automatizovanými nástrojmi. Tento prehľadový článok porovnáva jazykové a behaviorálne príznaky používané na ich detekciu, venuje sa hybridným a grafovým modelom, recenziám generovaným veľkými jazykovými modelmi a požiadavke na vysvetliteľnosť. Na základe prehľadu identifikujeme otvorené problémy, najmä nedostatok slovenských a českých dát, studený štart a posun distribúcie, a načrtávame smerovanie ďalšieho výskumu.

1 Úvod

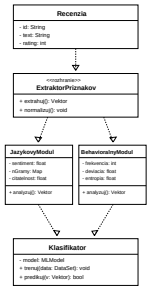
Online recenzie sa stali jedným z najvplyvnejších signálov pri nákupe tovarov a služieb. Ovplyvňujú predajnosť produktov, reputáciu podnikov a rozhodovanie spotrebiteľov, a preto vytvárajú silnú motiváciu manipulovať recenzným priestorom: objednávať pozitívne hodnotenia, znevažovať konkurenciu alebo hromadne vytvárať účty, ktoré sa navzájom podporujú. Falošné recenzie tak poškodzujú spotrebiteľov, znižujú dôveryhodnosť platforiem a vytvárajú nekalú konkurenčnú výhodu.

S rozvojom veľkých jazykových modelov (LLM) sa výrazne znížil náklad na vytvorenie plynulého a štylisticky presvedčivého textu. Tradičné detektory založené na povrchových lexikálnych znakoch strácajú spoľahlivosť a čoraz väčší význam nadobúdajú behaviorálne a relačné signály, ktoré opisujú, *ako* a *kedy* recenzia vznikla. Zároveň rastú požiadavky na vysvetliteľnosť: moderátor platformy musí vedieť rozhodnutie o označení recenzie obhájiť, čo súvisí aj s reguláciou zavádzajúcich recenzií v EÚ.

*Semestrálny projekt v predmete Metódy inžinierskej práce, ak. rok 2026/27, vedenie: Ing. Ivan Kapustík



Obr. 1: Proces detekcie recenzií



Obr. 2: Architektúra extrakcie príznakov

V článku si kladieme štyri výskumné otázky: (RQ1) ktoré jazykové príznaky sú spojené s falošnými recenziami; (RQ2) ktoré behaviorálne a grafové príznaky zachytávajú koordinované podvody; (RQ3) ako tieto skupiny kombinovať; a (RQ4) ktoré problémy zostávajú otvorené v ére generatívnych modelov. Pri spracovaní témy nás primárne usmernila prehľadová práca [1]; za zakladajúcu prácu oblasti považujeme [2]. Prínos článku je v spojení jazykového a behaviorálneho pohľadu a vo vymedzení medzery, na ktorú nadväzuje náš ďalší výskum. Časť 2 predstavuje súvisiace práce a taxonómiu, časti 3 a 4 porovnávajú dve skupiny príznakov, časť 5 sa venuje hybridným prístupom, časť 6 ich porovnáva a formuluje otvorené problémy, časť 7 načrtáva naše smerovanie a časť 8 uzatvára článok.

2 Súvisiace práce a taxonómia

Jindal a Liu [2] ako prví systematicky kategorizovali recenzný spam a rozlíšili nepravdivé recenzie, recenzie propagujúce iba značku a recenzie, ktoré vôbec nie sú recenziami produktu. Ott a kol. [3] vytvorili prvý štandardizovaný dataset klamlivých recenzií a ukázali, že n-gramy a psycholingvistické lexikóny prekonávajú ľudských posudzovateľov; zároveň upozornili, že pri autenticky pôsobiacich textoch sa klasifikátor môže učiť idiosynkrázie konkrétnych autorov. Luca a Zervas [4] na dátach z Yelpu dokumentovali, že podniky s horšou reputáciou častejšie objednávajú falošné pozitívne recenzie. Mukherjee a kol. [5] ukázali, že behaviorálne príznaky môžu byť informatívnejšie než samotný text.

Samostatnú líniu predstavujú práce o koordinovaných skupinách a recenzných sieťach. Mukherjee a kol. [6] odhaľovali falošné recenzentské skupiny podľa spoločného správania a synchronizovaného publikovania. Rayana a Akoglu [7] spojili recenzie, recenzentov a produkty do jednej siete a využili šírenie podozrenia medzi prepojenými entitami.

Prehľadové práce [1] a [8] zjednotili terminológiu a rozdelili prístupy podľa typu príznakov a úrovne rozhodovania. Barbado a kol. [9] overili aplikačný rozmer na doméne spotrebnej elektroniky a Li a kol. [10] ukázali, že existujú relatívne univerzálne, ľudsky interpretovateľné pravidlá prekračujúce hranice datasetu.

Recenzný spam možno deliť podľa zámeru (propagácia vlastnej ponuky,

poškodenie konkurencie), pôvodcu (ľudský, platený, konkurenčný, automatizovaný), úrovne (recenzia, recenzent, produkt, skupina) a času (jednorazový, koordinovaný). Rôzne typy podvodov zanechávajú rôzne stopy: jazykové príznaky sú silnejšie pri nešikovne vytvorených textoch, behaviorálne a grafové pri koordinovaných kampaniach. Zhao a kol. [11] napokon ukázali, že AI-generované recenzie sú plynulejšie a štylisticky konzistentnejšie než ľudské, čo je hlavný dôvod, prečo sa výskum obracia k hybridným prístupom.

3 Jazykové príznaky

Jazykové príznaky vychádzajú z predpokladu, že autori vymyslených recenzií používajú odlišné štylistické, syntaktické a sémantické vzory než reálni zákazníci. Medzi kľúčové metriky patria:

- **Lexikálna bohatosť:** Type-Token Ratio, priemerná dĺžka slova a slovná zásoba. Nižšia lexikálna rozmanitosť sa pri falošných recenziách uvádza často, výsledky však závisia od dĺžky textu a domény, preto treba TTR normalizovať [3, 8].
- **Distribúcia slovných druhov a syntax:** klamlivé recenzie obsahujú pomerne viac slovies, prísloviek a zámen, pravdivé viac podstatných a prídavných mien a predložiek [3]. Doplnkovými znakmi sú dĺžka viet, interpunkcia a opakovanie šablón.
- **Sémantika a sentiment:** polarita, subjektivita, extrémnosť hodnotenia a miera konkrétnych, overiteľných detailov. Extrémne hodnotenia s malým množstvom vecných argumentov patria medzi rizikovejšie [10].
- **Neurónové reprezentácie:** jemne doladené transformery, napr. BERT [12], zachytávajú kontextové vzory neviditeľné pre n-gramy; pri generovaných textoch sa dopĺňa perplexita a miera „hladkosti“ [11].

Jazykové príznaky nie sú univerzálne: závisia od jazyka, domény, dĺžky recenzie a pôvodcu textu. Pri ľuďmi písaných recenziách sa detektory učia idiosynkrázie autorov, pri LLM-generovaných textoch zase vlastnosti konkrétneho modelu, čo vedie k slabej generalizácii a rýchlemu zastarávaniu. Sú však lacné, dostupné aj pri novom recenzentovi a interpretovateľné, preto zostávajú dôležitou súčasťou hybridných riešení. Na obr. 1 a 2 sú znázornené diagramy vytvorené v nástroji UMLet/UMLetino: proces detekcie a architektúra tried extraktora príznakov.

4 Behaviorálne príznaky

Behaviorálne príznaky sledujú, ako sa recenzent a platforma správajú v čase. Ide o signály, ktoré podvodník napodobňuje ťažšie, pretože si vyžadujú históriu účtu, kontext produktu alebo vzťahy medzi entitami:

- **Recenzent:** vek účtu, počet recenzií, pomer recenzií k nákupom, overený nákup, kompletnosť profilu a podiel extrémnych hodnotení.

- **Recenzia a produkt:** dĺžka, čas publikovania, duplicitný text, odchýlka od priemeru produktu a náhle zmeny priemerného hodnotenia.
- **Čas:** burstiness, periodicita, synchronizácia viacerých účtov a časový posun voči uvedeniu produktu na trh.
- **Graf a vzťahy:** bipartitný graf recenzent–produkt, ko-recenzné skupiny a šírenie podozrenia v sieti [6, 7].

Na reprezentáciu kombinácie jazykových a behaviorálnych metrík slúži matica príznakov $\mathbf{X}_{5\times 4}$ v rovnici (1), kde riadky zodpovedajú recenziám a stĺpce ilustračným hodnotám sentimentu, lexikálnej diverzity, frekvencie publikovania a odchýlky hodnotenia od priemeru:

$$\mathbf{X}_{5\times 4} = \begin{pmatrix} 0.82 & 0.15 & 14.5 & 2.40 \\ -0.45 & 0.78 & 1.2 & 0.15 \\ 0.94 & 0.05 & 28.0 & 2.85 \\ 0.12 & 0.65 & 2.1 & 0.40 \\ -0.78 & 0.42 & 19.3 & 2.10 \end{pmatrix} \tag{1}$$

Dôveryhodnosť recenzenta u po n recenziách modelujeme exponenciálnym vyhladzovaním:

$$T_n(u) = (1-\alpha)^n T_0(u) + \alpha(1-\alpha)^{n-1}\phi\big(r_1(u)\big) + \cdots \\ + \alpha(1-\alpha)\phi\big(r_{n-1}(u)\big) + \alpha\phi\big(r_n(u)\big), \tag{2}$$

kde $\alpha \in (0,1)$ je miera učenia a $\phi(r_k(u)) \in \langle 0,1\rangle$ je normalizovaný signál autentickosti k-tej recenzie. Model je jednoduchý, interpretovateľný a umožňuje priebežnú aktualizáciu bez prepočítavania celej histórie.

Behaviorálne príznaky majú dve obmedzenia: *studený štart* pri nových recenzentoch a dostupnosť citlivých dát. Platformy často nezverejňujú históriu používateľov a spracovanie osobných údajov podlieha GDPR; riešením je agregácia, anonymizácia a používanie verejných datasetov či spolupráca s platformami.

5 Hybridné a moderné prístupy

Hybridné prístupy kombinujú obe skupiny na úrovni príznakov (early fusion), rozhodnutí (late fusion) alebo spoločného modelu. V praxi sa osvedčili gradientové boosting stromy, ansámble a grafové neurónové siete, ktoré prirodzene spracúvajú vzťahy medzi recenzentmi, recenziami a produktmi [7]. Heterogénne grafy dokážu šíriť podozrenie z podozrivých účtov na susedov a odhaliť kampane neviditeľné na úrovni jednotlivej recenzie; výzvou zostáva dynamika grafu, škálovateľnosť a vysvetliteľnosť.

Vysvetliteľnosť je pri nasadení kľúčová: moderátor musí vedieť, prečo bola recenzia označená, aby rozhodnutie obhájil a nepoškodzoval legitímnych používateľov. Preto sa popri presnosti hodnotia atribúcie príznakov (SHAP [13], LIME), pozornosť modelu a proti-faktuálne vysvetlenia. V našom poňatí je vysvetliteľnosť rovnocenným cieľom, nie doplnkovou funkcionalitou.

Osobitnú výzvu predstavujú recenzie generované LLM. Sú plynulé a štylisticky konzistentné, takže lexikálne a štylometrické príznaky strácajú

Tabuľka 1: Porovnanie skupín príznakov a prístupov k detekcii falošných recenzií

Prístup	Typické príznaky	Silné stránky	Obmedzenia
Jazykový	n-gramy, TTR, slovné druhy, LIWC, sentiment, perplexita	dostupný aj pri novom recenzentovi; interpretovateľný; lacný	závislý od jazyka a domény; zlyháva pri LLM
Behaviorálny	vek účtu, frekvencia, burstiness, odchýlka ratingu	odolný voči štylistickým úpravám; zachytáva koordináciu	studený štart; GDPR a dostupnosť dát
Grafový	bipartitné grafy, ko-recenzné skupiny, šírenie podozrenia	odhaľuje skupiny a kampane	náročný na dáta a výpočet; horšia vysvetliteľnosť
Hybridný	spojenie textových, behaviorálnych a grafových príznakov	najlepšia presnosť a robustnosť	zložitosť; riziko preučenia; náročná údržba
LLM-orientovaný	detekcia generovaného textu, perplexita, adversariálne testovanie	reaguje na novú hrozbu	rýchly vývoj modelov; neistá generalizácia

silu [11]. Behaviorálne signály zostávajú účinné, ale aj tie možno obchádzať farmárskymi účtami. Výskum sa preto uberá k detekcii generovaného textu, adaptívnemu učeniu a adversariálnemu testovaniu. Hodnotenie si vyžaduje časové alebo doménové rozdelenie dát, sledovanie F1, AUROC, miery falošných pozitív pri fixnom zachytení a kalibrácie.

6 Porovnanie prístupov a otvorené problémy

Tabuľka 1 zhrňuje hlavné skupiny prístupov. Jazykové metódy sú lacné a dostupné, ale krehké voči LLM a zmene domény. Behaviorálne metódy sú odolnejšie voči štylistickým úpravám, vyžadujú však históriu a citlivé dáta. Grafové metódy najlepšie zachytávajú koordinované skupiny, no sú náročné na dáta a vysvetlenie. Hybridné riešenia dosahujú najlepší kompromis, ale zvyšujú zložitosť systému.

Otvorených problémov zostáva niekoľko: nedostatok dát pre slovenský a český jazyk, studený štart nových recenzentov, posun distribúcie (*concept drift*), adversariálne prispôsobovanie a spravodlivosť modelov. Práve z nich vyplýva medzera, na ktorú sa zameriavame: chýba otvorený slovensko-anglický dataset, systematické porovnanie jazykových a behaviorálnych príznakov v podmienkach LLM a prakticky použiteľný hybridný detektor s vysvetliteľnými výstupmi.

7 Navrhovaný prístup

Navrhujeme modulárny hybridný detektor v štyroch vrstvách: zber a anotácia dát, extrakcia jazykových a behaviorálnych príznakov, hybridný klasifikátor doplnený o grafové príznaky a vrstva vysvetlenia pre moderátora. Predbežné plánovacie ciele sú anotovaný dvojjazyčný dataset s cieľovou veľkosťou 15 000 recenzií a zhodou anotátorov $\kappa \geq 0{,}7$; počiatočné prahy F1 sú 0,80 pre jazykový model, 0,75 pre behaviorálny/grafový model a 0,85 pre hybridný model v rámci domény, s cieľom 0,75 pri prenose na novú doménu. Tieto hodnoty sú pracovné

ciele, nie namerané výsledky: kalibrujú sa po baseline experimentoch. Hybridný model má prekonať samostatné modely v porovnateľnom teste. Latencia API sa bude merať v pilote; cieľový limit sa stanoví po dohode s potenciálnym používateľom. Pilot sa uskutoční s partnerskou platformou, ak sa podarí zabezpečiť prístup, inak sa použije offline test na dostupných dátach. Počet recenzií, prahové hodnoty F1 a rozsah pilotu sú predbežné predpoklady, ktoré sa overia po audite dát a kapacít tímu.

8 Záver

Článok porovnal jazykové, behaviorálne, grafové a hybridné prístupy k detekcii falošných recenzií. Jazykové príznaky sú užitočné pri lacnej prvotnej filtrácii, behaviorálne a grafové odhaľujú koordinované kampane a sú odolnejšie voči štylistickým úpravám. V ére LLM sa ťažisko presúva k hybridným riešeniam s vysvetliteľnými výstupmi. Otvorené zostávajú otázky slovenských a českých dát, studeného štartu, posunu distribúcie a adversariálneho prispôsobovania; na ne sa zameriava náš ďalší výskum.

Na výskumné otázky odpovedáme takto. (RQ1) Najčastejšie spájané jazykové príznaky sú lexikálna rozmanitosť (normalizované TTR), distribúcia slovných druhov, extrémnosť sentimentu a štylometrické markery; ich prínos je najväčší pri lacnej prvotnej filtrácii a pri nešikovne vytvorených textoch. (RQ2) Behaviorálne a grafové príznaky zachytávajú koordinované podvody, najmä pri skupinách recenzentov, burstiness a šírení podozrenia medzi prepojenými entitami. (RQ3) Kombinácia skupín sa najčastejšie robí early fusion alebo late fusion; osvedčené sú stromové ansámble a grafové neurónové siete, pričom ich výhoda sa musí overiť na časovo a doménovo oddelených dátach. (RQ4) Otvorené zostávajú nedostatok slovenských a českých dát, studený štart, posun distribúcie a adversariálne prispôsobovanie generovaných textov.

Literatúra

[1] Michael Crawford, Taghi M. Khoshgoftaar, Joseph D. Prusa, Aaron N. Richter, and Hamzah Al Najada. Survey of review spam detection using machine learning techniques. *Journal of Big Data*, 2(1):23, 2015.

[2] Nitin Jindal and Bing Liu. Opinion spam and analysis. In *Proceedings of the 2008 International Conference on Web Search and Data Mining (WSDM)*, pages 219–230. ACM, 2008.

[3] Myle Ott, Yejin Choi, Claire Cardie, and Jeffrey T. Hancock. Finding deceptive opinion spam by any stretch of the imagination. In *Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics*, pages 309–319, 2011.

[4] Michael Luca and Georgios Zervas. Fake it till you make it: Reputation, competition, and Yelp review fraud. *Management Science*, 62(12):3412–3427, 2016.

[5] Arjun Mukherjee, Vivek Venkataraman, Bing Liu, and Natalie Glance. What Yelp fake review filter might be doing? In *Proceedings of the International AAAI Conference on Web and Social Media*, volume 7, pages 409–418, 2013.

[6] Arjun Mukherjee, Bing Liu, and Natalie Glance. Spotting fake reviewer groups in consumer reviews. In *Proceedings of the 21st International Conference on World Wide Web (WWW)*, pages 191–200. ACM, 2012.

[7] Shebuti Rayana and Leman Akoglu. Collective opinion spam detection: Bridging review networks and metadata. In *Proceedings of the 21st ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pages 985–994. ACM, 2015.

[8] Atefeh Heydari, Mohammad Ali Tavakoli, Naomie Salim, and Zahra Heydari. Detection of review spam: A survey. *Expert Systems with Applications*, 42(7):3634–3642, 2015.

[9] Rodrigo Barbado, Oscar Araque, and Carlos A. Iglesias. A framework for fake review detection in online consumer electronics retailers. *Information Processing & Management*, 56(4):1234–1244, 2019.

[10] Jiwei Li, Myle Ott, Claire Cardie, and Eduard Hovy. Towards a general rule for identifying deceptive opinion spam. In *Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1566–1576. Association for Computational Linguistics, 2014.

[11] Yuexin Zhao, Siyi Tang, Hongyu Zhang, and Long Lyu. AI vs. human: A large-scale analysis of AI-generated fake reviews, human-generated fake reviews and authentic reviews. *Journal of Retailing and Consumer Services*, 87:104400, 2025.

[12] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*, pages 4171–4186, 2019.

[13] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Proceedings of the 31st International Conference on Neural Information Processing Systems (NeurIPS)*, pages 4765–4774, 2017.