Detekcia falošných online recenzií na základe jazykových a behaviorálnych príznakov

Metódy inžinierskej práce 2026/27

Matvii Nosenko, Volodymyr Nedoluha
Danylo Nikolenko, Rostyslav Mykytiuk

Fakulta informatiky a informačných technológií
Slovenská technická univerzita v Bratislave

3. novembra 2026

O čom to je

Online recenzie sú jedným z najvplyvnejších signálov pri nákupe tovarov a služieb. Ich dôveryhodnosť však narúšajú falošné recenzie vytvárané firmami, platenými recenzentmi, konkurenciou či automatizovanými nástrojmi.
Ponúkame prehľad metód detekcie a porovnávame dve hlavné skupiny príznakov: *jazykové* (čo recenzia hovorí a ako je napísaná) a *behaviorálne* (ako a kedy recenzent a platforma konajú).

Prehľad

1. Úvod a motivácia
2. Súvisiace práce
3. Jazykové príznaky
4. Behaviorálne príznaky
5. Hybridné prístupy
6. Porovnanie a otvorené problémy
7. Navrhovaný prístup

Prečo je to dôležité

- Falošné recenzie poškodzujú spotrebiteľov a platformy
  - objednané pozitívne hodnotenia zvyšujú predajnosť
  - znevažovanie konkurencie vytvára nekalú výhodu
- Veľké jazykové modely (LLM) znížili náklady na tvorbu plynulého textu
  - lexikálne detektory strácajú spoľahlivosť
  - rastie význam behaviorálnych a relačných signálov
- Požaduje sa *vysvetliteľnosť* rozhodnutia moderátora

Výskumné otázky

- **RQ1:** Ktoré jazykové príznaky sú spojené s falošnými recenziami?
- **RQ2:** Ktoré behaviorálne a grafové príznaky zachytávajú koordinované podvody?
- **RQ3:** Ako tieto skupiny príznakov kombinovať?
- **RQ4:** Ktoré problémy zostávajú otvorené v ére generatívnych modelov?

Kľúčové práce v oblasti

- Jindal a Liu [1] ako prví kategorizovali recenzný spam
- Ott a kol. [2] vytvorili prvý štandardizovaný dataset
  - n-gramy a psycholingvistické lexikóny prekonávajú ľudí
  - klasifikátor sa učí idiosynkrázie autorov
- Mukherjee a kol. [3] ukázali silu behaviorálnych príznakov
- Rayana a Akoglu [4] spojili recenzie, recenzentov a produkty do jednej siete

[1] Jindal & Liu, 2008
[2] Ott et al., 2011
[3] Mukherjee et al., 2013
[4] Rayana & Akoglu, 2015

Jazykové príznaky

- **Lexikálna bohatosť:** Type-Token Ratio, dĺžka slov, slovná zásoba
  - nižšia rozmanitosť sa spája s falošnými recenziami
  - TTR treba normalizovať podľa dĺžky textu
- **Syntax a slovné druhy:** viac slovies, prísloviek a zámen
- **Sémantika a sentiment:** polarita, extrémnosť hodnotenia
- **Neurónové reprezentácie:** jemne doladené transformery (BERT)

Obmedzenia jazykových príznakov

- Nie sú univerzálne: závisia od jazyka, domény a dĺžky recenzie
- Slabá generalizácia a rýchle zastarávanie pri LLM-generovanom texte
- Napriek tomu zostávajú *lacné, dostupné a interpretovateľné*

Behaviorálne príznaky

- **Recenzent:** vek účtu, počet recenzií, overený nákup, kompletnosť profilu
- **Recenzia a produkt:** čas publikovania, duplicitný text, odchýlka od priemeru
- **Čas:** burstiness, periodicita, synchronizácia účtov
- **Graf a vzťahy:**
  - bipartitný graf recenzent–produkt
  - ko-recenzné skupiny a šírenie podozrenia v sieti

Model dôveryhodnosti recenzenta

Dôveryhodnosť recenzenta u po n recenziách modelujeme exponenciálnym vyhladzovaním:

$$T_n(u) = (1-\alpha)^n T_0(u) + \alpha(1-\alpha)^{n-1}\phi(r_1(u)) + \cdots + \alpha\phi(r_n(u)),$$

kde $\alpha \in (0,1)$ je miera učenia a $\phi(r_k(u)) \in \langle 0,1\rangle$ je normalizovaný signál autentickosti k-tej recenzie.

Proces detekcie – diagram z UMLet

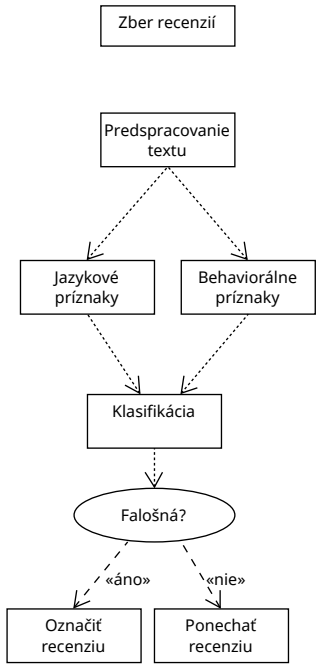


Diagram vytvorený v nástroji UMLet/UMLetino (`img/diagram1.pdf`).

Hybridné a moderné prístupy

- Spojenie skupín príznakov na úrovni:
  - príznakov (*early fusion*)
  - rozhodnutí (*late fusion*)
  - spoločného modelu
- Osvedčené: gradientové boosting stromy, ansámble, grafové neurónové siete
- *Vysvetliteľnosť* je rovnocenný cieľ, nie doplnková funkcionalita
- Osobitná výzva: recenzie generované LLM

Porovnanie skupín príznakov

Prístup	**Príznaky**	**Silné stránky**	**Obmedzenia**
Jazykový	n-gramy, TTR, sentiment	lacný, interpretovateľný	krehký voči LLM
Behaviorálny	frekvencia, burstiness	odolný, zachytáva koordináciu	studený štart, GDPR
Grafový	bipartitné grafy	odhaľuje skupiny a kampane	náročný na dáta
Hybridný	spojenie všetkých	najlepšia presnosť	zložitosť, preučenie

- Otvorené: málo slovenských/českých dát, studený štart, *concept drift*

Náš modulárny hybridný detektor

- Štyri vrstvy:
  - zber a anotácia dát
  - extrakcia jazykových a behaviorálnych príznakov
  - hybridný klasifikátor s grafovými príznakmi
  - vrstva vysvetlenia pre moderátora
- Predbežné ciele: dvojjazyčný dataset (15 000 recenzií), $\kappa \geq 0{,}7$
- Cieľové F1: 0,80 jazykový / 0,75 behaviorálny / 0,85 hybridný model

Zhodnotenie a ďalšia práca

- Jazykové príznaky sú vhodné na lacnú prvotnú filtráciu
- Behaviorálne a grafové príznaky odhaľujú koordinované kampane
- V ére LLM sa ťažisko presúva k hybridným riešeniam s vysvetliteľnými výstupmi
- Ďalej: slovensko-anglický dataset a prakticky použiteľný hybridný detektor