Detekcia falošných online recenzií na základe jazykových a behaviorálnych príznakov

Prezentácia projektu **FAKERADAR**

Semestrálny projekt v predmete Metódy inžinierskej práce, ak. rok 2026/27

Matvii Nosenko, Volodymyr Nedoluha,
Danylo Nikolenko, Rostyslav Mykytiuk

Fakulta informatiky a informačných technológií
Slovenská technická univerzita v Bratislave
Vedenie projektu: Ing. Ivan Kapustík

prezentácia projektu ▪ zimný semester 2026/27

STU FIIT
SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE
FAKULTA INFORMATIKY A INFORMAČNÝCH TECHNOLÓGIÍ

Motivácia

- Online recenzie ovplyvňujú **predaj, reputáciu aj rozhodovanie** spotrebiteľov [1]
- Falošné recenzie vytvárajú firmy, platení recenzenti, konkurencia aj **automatizované nástroje**
- V ére veľkých jazykových modelov (LLM) je vymyslený text *plynulý a lacný* — povrchové detektory strácajú spoľahlivosť [2]
- Potrebné je **hybridné** riešenie: jazykové + behaviorálne príznaky, grafy a *vysvetliteľný* výstup pre moderátora

Cieľ projektu FAKERADAR

Navrhnúť a overiť modulárny, vysvetliteľný hybridný detektor falošných recenzií vrátane prvej dvojjazyčnej (slovensko-anglickej) dátovej sady.

[1] Luca a Zervas, Management Science 2016

[2] Zhao a kol., J. Retailing Consum. Serv. 2025

Prehľad

1. Úvod a ciele projektu
2. Súčasný stav v oblasti
3. Porovnanie prístupov
4. Navrhovaný prístup a plán

Úvod a ciele projektu

prednáša: **Matvii Nosenko**

Výskumné otázky a ciele

- **RQ1:** Ktoré jazykové príznaky sú spojené s falošnými recenziami?
- **RQ2:** Ktoré behaviorálne a grafové príznaky zachytávajú koordinované podvody?
- **RQ3:** Ako tieto skupiny príznakov *kombinovať* (early/late fusion)?
- **RQ4:** Ktoré problémy zostávajú otvorené v ére generatívnych modelov?
- Ciele projektu
  - dvojjazyčná anotovaná dátová sada recenzií
  - porovnanie jazykových a behaviorálnych príznakov v podmienkach LLM
  - hybridný detektor s vysvetliteľnými výstupmi
- Primárne usmernenie: prehľad Crawford a kol. 2015; zakladajúca práca oblasti: Jindal a Liu 2008

Súčasný stav v oblasti

prednáša: **Volodymyr Nedoluha**

Taxonómia recenzného spamu a súvisiace práce

- Delenie podľa Jindala a Liua (2008):
  - *nepravdivé* recenzie, recenzie propagujúce značku, nerecenzie produktu
- Prvý štandardizovaný dataset a n-gramové detektory: Ott a kol. (2011)
- Behaviorálne príznaky môžu byť **informatívnejšie** než samotný text: Mukherjee a kol. (2013)
- Koordinované skupiny a siete: Mukherjee a kol. (2012), Rayana a Akoglu (2015)
- Prehľady a pravidlá zovšeobecňujúce datasety: Crawford a kol. (2015), Heydari a kol. (2015), Li a kol. (2014)
- Aplikačný rámec pre spotrebnú elektroniku: Barbado a kol. (2019)

Zdroje: plný zoznam na poslednom slajde; článok odkazuje na 12+ zdrojov cez BibTeX.

Jazykové príznaky

- **Lexikálna bohatosť:** Type-Token Ratio (normalizovaný), dĺžka slova, slovná zásoba [3]
- **Syntax a slovné druhy:** falošné recenzie → viac slovies, prísloviek a zámen; reálne → viac podstatných mien
- **Sémantika a sentiment:** extrémne hodnotenie, málo overiteľných detailov [4]
- **Neurónové reprezentácie:** jemne doladené transformery (BERT) + perplexita generovaných textov [5]
- Výhody: lacné, dostupné pri novom recenzentovi, interpretovateľné
- Riziko: *učenie sa idiosynkrázií* autorov/modelov ⇒ slaba generalizácia

[3] Ott a kol. 2011; Heydari a kol. 2015

[4] Li a kol. 2014

[5] Devlin a kol. 2019; Zhao a kol. 2025

Behaviorálne a grafové príznaky

- **Recenzent:** vek účtu, pomer recenzií k nákupom, podiel extrémnych hodnotení
- **Recenzia a produkt:** duplicitný text, odchýlka od priemeru, náhle zmeny ratingu
- **Čas:** burstiness, periodicita, synchronizácia účtov (burstové kampane)
- **Graf:** bipartitný graf recenzent–produkt, ko-recenzné skupiny, šírenie podozrenia [6]

Dôveryhodnosť recenzenta ako exponenciálne vyhladzovanie

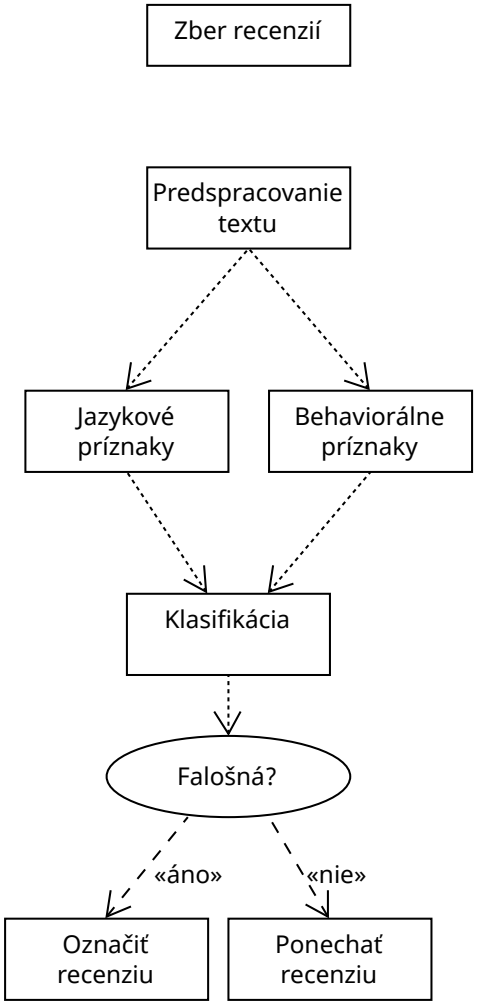
$$T_n(u) = \alpha\,\phi\big(r_n(u)\big) + (1-\alpha)\,T_{n-1}(u), \qquad \alpha \in (0,1)$$

$\phi \in \langle 0,1\rangle$ — normalizovaný signál autentickosti n-tej recenzie

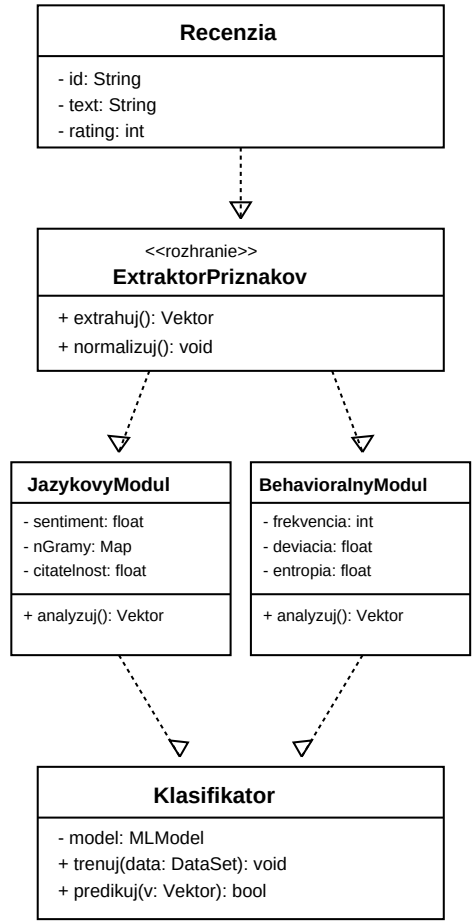
Obmedzenia: studený štart nových recenzentov, dostupnosť dát a GDPR.

[6] Mukherjee a kol. 2012; Rayana a Akoglu 2015

Diagram: proces detekcie a architektúra extrakcie príznakov



Proces detekcie recenzií



Architektúra tried extraktora príznakov

Diagramy vytvorené v nástroji **UMLet** (zdrojové súbory: `img/diagram1.uxf`, `img/diagram2.uxf`).

Porovnanie prístupov

prednáša: **Danylo Nikolenko**

Hybridné prístupy a výzva LLM

- Kombinácia príznakových skupín: **early fusion** (úroveň príznakov) alebo **late fusion** (úroveň rozhodnutí)
- Osvedčené modely: gradientové boosting stromy, ansámble, *grafové neurónové siete* [7]
- Grafy šíria podozrenie na susedov ⇒ odhalia **kampane neviditeľné na úrovni jednej recenzie**
- **Vysvetliteľnosť** ako rovnocenný cieľ: moderátor musí rozhodnutie obhájiť — SHAP/LIME, pozornosť, protifaktuály [8]
- LLM-generované recenzie: plynulé a konzistentné ⇒ lexikálne príznaky strácajú silu [9]
- Evaluácia: časové/doménové rozdelenie dát, F1, AUROC, falošné pozitíva pri fixnom zachytení, kalibrácia

[7] Rayana a Akoglu 2015
[8] Lundberg a Lee 2017
[9] Zhao a kol. 2025

Porovnanie skupín prístupov

Prístup	Typické príznaky	Silné stránky	Obmedzenia
Jazykový	n-gramy, TTR, slovné druhy, sentiment, perplexita	dostupný pri novom recenzentovi; interpretovateľný; lacný	závislý od jazyka a domény; zlyháva pri LLM
Behaviorálny	vek účtu, frekvencia, burstiness, odchýlka ratingu	odolný voči štylistickým úpravám; zachytáva koordináciu	studený štart; GDPR a dostupnosť dát
Grafový	bipartitné grafy, ko-recenzné skupiny, šírenie podozrenia	odhaľuje skupiny a kampane	náročný na dáta a výpočet; horšia vysvetliteľnosť
Hybridný	spojenie textových, behaviorálnych a grafových príznakov	najlepšia presnosť a robustnosť	zložitosť; riziko preučenia; náročná údržba
LLM-orientovaný	detekcia generovaného textu, adversariálne testovanie	reaguje na novú hrozbu	rýchly vývoj modelov; neistá generalizácia

Tabuľka: Porovnanie skupín príznakov a prístupov k detekcii falošných recenzií.

Vážené vyhodnotenie prístupov (tabuľka z Excelu)

Kritérium (skóre 1–5)	Váha	Jazyk.	Behav.	Graf.	Hybrid.
Presnosť v rámci domény	0,25	3	3	4	**5**
Odolnosť voči LLM-generovaným textom	0,20	1	4	3	**4**
Zachytenie koordinovaných kampaní	0,15	1	4	5	**5**
Interpretovateľnosť výstupu	0,20	**5**	3	2	4
Dostupnosť dát pri štarte	0,10	**5**	2	1	3
Škálovateľnosť a náklady	0,10	**4**	3	2	3
Vážené skóre (vzorec)	1,00	3,00	3,25	3,05	**4,20**

Tabuľka: Multikritériálne vyhodnotenie prístupov.

Tabuľka spracovaná v LibreOffice Calc: `tabulky/tabulky_fakeradar.xlsx`, list „Vyhodnotenie“;

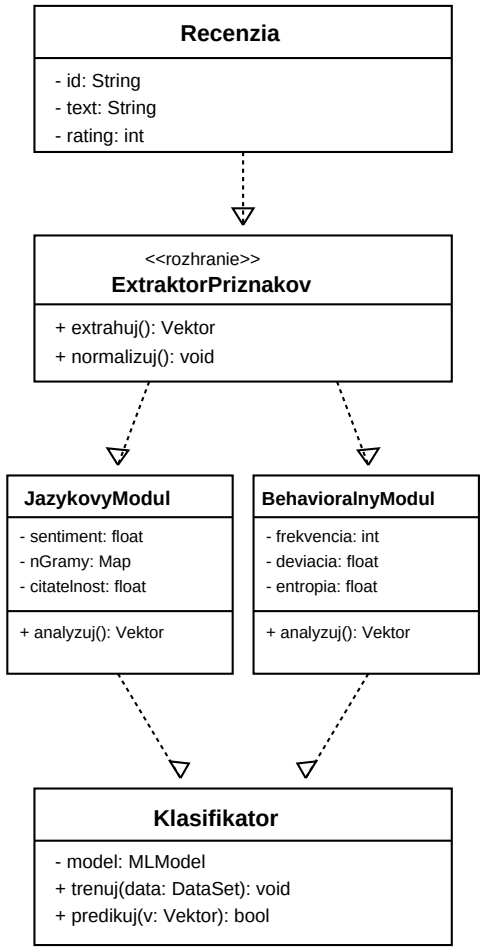
posledný riadok počíta funkcia `=SUMPRODUCT(váhy; skóre)`, váhy overuje `=SUM(...)` $= 1$.

Navrhovaný prístup a plán

prednáša: **Rostyslav Mykytiuk**

FAKERADAR: modulárny hybridný detektor

- **1. Zber a anotácia dát** — dvojjazyčná sada, medzanotátorská zhoda
- **2. Extrakcia príznakov** — jazykové (text) + behaviorálne a grafové (správanie)
- **3. Hybridný klasifikátor** — early/late fusion + grafové príznaky
- **4. Vrstva vysvetlenia** — atribúcie príznakov pre moderátora



Architektúra extraktora príznakov (UMLet)

Merateľné ciele a ukazovatele

- **Dátová sada:** 15 000 anotovaných recenzií (sk/en), zhoda anotátorov $\kappa \geq 0{,}7$ [10]
- **Presnosť (F1, rámec domény):** jazykový model $\geq 0{,}80$; behaviorálny/grafový $\geq 0{,}75$; *hybridný* $\geq 0{,}85$
- **Prenos na novú doménu:** F1 $\geq 0{,}75$; hodnotenie aj na časovo oddelených dátach (concept drift)
- **Hybridný model má prekonať** samostatné modely v porovnateľnom teste
- **Pilot:** s partnerskou platformou (pri dohode), inak offline test na dostupných dátach; latencia API sa meria
- Kalibrácia prahov až po baseline experimentoch — predbežné ciele sú pracovné, nie namerané

[10] Landis a Koch 1977

Plán prác a rozdelenie v tíme

	Pracovný balík	Obdobie (mes.)	Vedúci WP
WP1	manažment, reporting a riadenie rizík	1–36	M. Nosenko
WP2	zber, anotácia a sprístupnenie dát	1–12	V. Nedoluha
WP3	jazykové modely a baseline experimenty	7–18	M. Nosenko
WP4	behaviorálne a grafové modely	13–24	V. Nedoluha
WP5	hybridný model, fúzia a vrstva vysvetliteľnosti	19–30	D. Nikolenko
WP6	pilotné overenie, prototyp API a evaluácia	25–36	R. Mykytiuk
WP7	diseminácia, dokumentácia a publikácie	1–36	R. Mykytiuk

Tabuľka: Sedem pracovných balíkov projektu (zodpovedá formuláru VV-F a článku; detailná kapacitná tabuľka po hodinách: `tabulky/tabulky_fakeradar.xlsx`, list „Harmonogram“, medzisúčty po riešiteľoch cez `=SUMIF`). Obdobie = mesiace od začiatku projektu (01/2027).

- Zodpovednosť za balíky kopíruje odborné špecializácie tímu a spresní sa pri štarte projektu
- Iteračný a inkrementálny postup: šprinty v Jira, revízie v Git-e

Zhodnotenie a ďalšia práca

- Jazykové príznaky = lacná **prvotná filtrácia**; behaviorálne a grafové odhaľujú **koordinované kampane**
- Ťažisko výskumu sa posúva k **hybridným riešeniam** s vysvetliteľnými výstupmi
- Otvorené problémy: slovenské/české dáta, studený štart, posun distribúcie, adversariálne prispôsobovanie
- Ďalšia práca: baseline experimenty na verejných datasetoch, tvorba dvojjazyčnej sady, kalibrácia cieľových hodnôt

Otázky na diskusiu

1. Má zmysel *zakázať* AI-generované recenzie, alebo ich iba *transparentne označovať*?
2. Ktorý kompromis preferuje moderátor: vyššia presnosť modelu alebo lepšia *vysvetliteľnosť* rozhodnutia?
3. Ako zachytiť podvod **v čase studeného štartu**, keď recenzent nemá žiadnu históriu?
4. Sú behaviorálne príznaky udržateľné vzhľadom na *GDPR* a súkromie používateľov?

Ďakujeme za pozornosť!

Otázky radi zodpovieme — diskutovať budú všetci členovia tímu.

Zdroje I

[1] Nitin Jindal and Bing Liu.
Opinion spam and analysis.
In *Proceedings of the 2008 International Conference on Web Search and Data Mining (WSDM)*, pages 219–230. ACM, 2008.

[2] Michael Luca and Georgios Zervas.
Fake it till you make it: Reputation, competition, and Yelp review fraud.
Management Science, 62(12):3412–3427, 2016.

[3] Arjun Mukherjee, Vivek Venkataraman, Bing Liu, and Natalie Glance.
What Yelp fake review filter might be doing?
In *Proceedings of the International AAAI Conference on Web and Social Media*, volume 7, pages 409–418, 2013.

[4] Myle Ott, Yejin Choi, Claire Cardie, and Jeffrey T. Hancock.
Finding deceptive opinion spam by any stretch of the imagination.
In *Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics*, pages 309–319, 2011.

[5] Michael Crawford, Taghi M. Khoshgoftaar, Joseph D. Prusa, Aaron N. Richter, and Hamzah Al Najada.
Survey of review spam detection using machine learning techniques.
Journal of Big Data, 2(1):23, 2015.

[6] Atefeh Heydari, Mohammad Ali Tavakoli, Naomie Salim, and Zahra Heydari.
Detection of review spam: A survey.
Expert Systems with Applications, 42(7):3634–3642, 2015.

Zdroje II

[7] Rodrigo Barbado, Oscar Araque, and Carlos A. Iglesias.
A framework for fake review detection in online consumer electronics retailers.
Information Processing & Management, 56(4):1234–1244, 2019.

[8] Arjun Mukherjee, Bing Liu, and Natalie Glance.
Spotting fake reviewer groups in consumer reviews.
In *Proceedings of the 21st International Conference on World Wide Web (WWW)*, pages 191–200. ACM, 2012.

[9] Shebuti Rayana and Leman Akoglu.
Collective opinion spam detection: Bridging review networks and metadata.
In *Proceedings of the 21st ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pages 985–994. ACM, 2015.

[10] Jiwei Li, Myle Ott, Claire Cardie, and Eduard Hovy.
Towards a general rule for identifying deceptive opinion spam.
In *Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1566–1576. Association for Computational Linguistics, 2014.

[11] Yuexin Zhao, Siyi Tang, Hongyu Zhang, and Long Lyu.
AI vs. human: A large-scale analysis of AI-generated fake reviews, human-generated fake reviews and authentic reviews.
Journal of Retailing and Consumer Services, 87:104400, 2025.

[12] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova.
BERT: Pre-training of deep bidirectional transformers for language understanding.
In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*, pages 4171–4186, 2019.

Zdroje III

[13] Scott M. Lundberg and Su-In Lee.
A unified approach to interpreting model predictions.
In *Proceedings of the 31st International Conference on Neural Information Processing Systems (NeurIPS)*, pages 4765–4774, 2017.

[14] J. Richard Landis and Gary G. Koch.
The measurement of observer agreement for categorical data.
Biometrics, 33(1):159–174, 1977.