**VV-F — Vecný zámer projektu**

Záväzná osnova pre aplikovaný výskum a vývoj

# Detekcia falošných online recenzií na základe jazykových a behaviorálnych príznakov

Detection of Fake Online Reviews Based on Linguistic and Behavioral Features

| | |
|---|---|
| **Akronym:** | FAKERADAR |
| **Evidenčné číslo:** | Zatiaľ nepridelené (študentský návrh) |
| **Žiadateľ:** | Slovenská technická univerzita v Bratislave, Fakulta informatiky a informačných technológií |
| **Zodpovedný riešiteľ:** | Ing. Ivan Kapustík |
| **Dátum:** | 01.11.2026 |
| **Obdobie riešenia:** | 01/2027 – 12/2029 |

Dokument je modelovým návrhom v rozsahu približne 50–60 % očakávanej finálnej verzie. Personálne a ekonomické údaje označené ako „doplniť“ treba pred finálnym podaním aktualizovať.

# 1 Excelentnosť

## 1.1 Projektový zámer a aplikačná úroveň

Online recenzie sú jedným z najvplyvnejších informačných kanálov v elektronickom obchode. Spotrebitelia na ich základe porovnávajú produkty, predajcov a ceny, podniky zase budujú reputáciu a konkurenčnú výhodu. Táto ekonomická hodnota vytvára motiváciu manipulovať recenzným priestorom prostredníctvom platených recenzentov, konkurenčných útokov, koordinovaných skupín účtov alebo automatizovaných nástrojov. Falošné recenzie preto poškodzujú spotrebiteľov, znižujú dôveryhodnosť platforiem a narúšajú férovú súťaž.

Projekt reaguje na medzeru medzi akademickými detektormi a potrebami praxe. Existujúce riešenia sú prevažne anglocentrické, založené na povrchových jazykových príznakoch a v podmienkach generatívnych modelov strácajú spoľahlivosť. Prevádzkovatelia platforiem zároveň potrebujú nielen presný, ale aj vysvetliteľný nástroj, ktorý dokáže rozhodnutie o označení recenzie zdôvodniť a ktorý je možné prevádzkovať bez neprimeraného zásahu do súkromia používateľov.

Projekt preto vyvinie hybridný detektor falošných recenzií, ktorý spája jazykové, behaviorálne a grafové príznaky, doplní ho o vrstvu vysvetlenia a overí v pilotnej prevádzke. Výstupom bude otvorený slovensko-anglický anotovaný dataset, metodika anotácie a hodnotenia, referenčný model, prototyp API a správa pre prax. Projekt začína na úrovni TRL 3 a končí na úrovni TRL 6: od overených laboratórnych postupov k funkčnému prototypu demonštrovanému v relevantnom prostredí.

## 1.2 Aktuálnosť a originalita

Aktuálnosť témy je daná tromi súbežnými trendmi. Prvým je rast elektronického obchodu a závislosti spotrebiteľov od recenzií. Druhým je dostupnosť veľkých jazykových modelov, ktoré dokážu generovať plynulé a štylisticky presvedčivé recenzie v takmer neobmedzenom množstve [1]. Tretím je regulácia: európsky rámec zakazuje zavádzajúce recenzie a posilňuje transparentnosť platforiem, čím vzniká dopyt po obhájiteľných nástrojoch moderovania.

Originalita projektu spočíva v piatich prvkoch. (i) Vytvoríme prvý otvorený slovensko-anglický benchmark pre detekciu falošných recenzií s viacnásobnou anotáciou. (ii) Spojíme textové, behaviorálne a grafové príznaky v jednom modeli a systematicky porovnáme ich prínos. (iii) Budeme explicitne modelovať recenzie generované LLM, nielen ľuďmi písaný spam. (iv) Vysvetliteľnosť bude rovnocenným cieľom, nie dodatočnou funkciou. (v) Výstupy budú otvorené a reprodukovateľné, aby ich mohli využiť ďalšie tímy aj prevádzkovatelia platforiem.

Nejde teda o ďalší izolovaný klasifikátor, ale o metodiku a nástroj, ktorý prepája výskum s moderovaním v praxi. Práve kombinácia dát, hybridného modelovania a vysvetliteľnosti vytvára priestor na originálny príspevok v slovenskom aj medzinárodnom kontexte.

## 1.3 Stav poznania a vedecké základy

Výskum detekcie falošných recenzií sa rozvíja od práce Jindala a Liu [2], ktorí vymedzili taxonómiu recenzného spamu a ukázali, že duplicitné texty sú silným indikátorom manipulácie. Ott a kol. [3] vytvorili prvý štandardizovaný dataset klamlivých recenzií a demonštrovali, že n-gramy a psycholingvistické lexikóny prekonávajú ľudských posudzovateľov. Ich práca zároveň upozornila na metodologický problém: pri autenticky pôsobiacich textoch sa klasifikátor môže učiť idiosynkrázie konkrétnych autorov namiesto všeobecného pojmu falošnosti.

Ekonomické motivácie analyzovali Luca a Zervas [4], ktorí dokumentovali vzťah medzi reputáciou podniku a objednávaním falošných pozitívnych recenzií. Mukherjee a kol. [5] ukázali, že behaviorálne príznaky môžu byť informatívnejšie než samotný text. Samostatnú líniu predstavujú práce o koordinovaných skupinách a recenzných sieťach: Mukherjee a kol. [6] odhaľovali falošné recenzentské

skupiny, Rayana a Akoglu [7] spojili recenzie, recenzentov a produkty do jednej siete a využili šírenie podozrenia medzi prepojenými entitami.

Prehľadové práce [8] a [9] zjednotili terminológiu a rozdelili prístupy podľa typu príznakov a úrovne rozhodovania. Barbado a kol. [10] overili aplikačný rozmer na doméne spotrebnej elektroniky a Li a kol. [11] ukázali, že existujú relatívne univerzálne, ľudsky interpretovateľné pravidlá prekračujúce hranice datasetu. Zhao a kol. [1] napokon dokumentovali, že AI-generované recenzie sú plynulejšie a štylisticky konzistentnejšie než ľudské, čo oslabuje čisto textové detektory.

Napriek tomuto pokroku zostávajú medzery, na ktoré projekt reaguje. Chýba otvorený slovensko-anglický dataset, systematické porovnanie jazykových a behaviorálnych príznakov v podmienkach LLM, prakticky použiteľný hybridný detektor s vysvetliteľnými výstupmi a metodika hodnotenia, ktorá zohľadňuje časový a doménový posun. Vedecké základy projektu preto tvoria štyri oblasti: spracovanie prirodzeného jazyka a štylometria, behaviorálna analýza a dolovanie v grafoch, strojové učenie s dôrazom na kalibráciu a generalizáciu a nakoniec výskum vysvetliteľnosti a používateľskej dôvery.

## 1.4 Ciele projektu

Ciele sú formulované merateľne a viažu sa na konkrétne výstupy a termíny.

| # | Cieľ | Ukazovateľ | Termín |
|---|---|---|---|
| O1 | Vytvoriť otvorený slovensko-anglický anotovaný dataset | minimálne 15 000 recenzií; $\kappa \geq 0{,}7$ | M12 |
| O2 | Vyvinúť jazykový model | F1 $\geq 0{,}80$ v rámci domény | M18 |
| O3 | Vyvinúť behaviorálny a grafový model | F1 $\geq 0{,}75$; odhalenie skupín | M24 |
| O4 | Skonštruovať hybridný model | F1 $\geq$ 0,85 in-domain; $\geq$ 0,75 cross-domain | M30 |
| O5 | Overiť prototyp v praxi | pilot s 1–2 platformami; vysvetlenie top-$k$ príznakov | M36 |

Ciele sú realistické vzhľadom na rozsah projektu, dostupné datasety a skúsenosti tímu. Zároveň sú dostatočne ambiciózne: vyžadujú nielen trénovanie modelov, ale aj tvorbu dát, anotáciu, evaluáciu a pilotné overenie. Splnenie cieľov budeme priebežne vyhodnocovať na míľnikoch M12, M24 a M36.

## 1.5 Metodológia

Metodológia je navrhnutá ako sekvencia ôsmich krokov, ktoré sa čiastočne prekrývajú.

**1. Zber dát.** Využijeme verejné datasety (napr. Ott a kol. [3]), verejne dostupné recenzie z platforiem a dátové zdroje partnerských organizácií. Doplníme ich syntetickými recenziami generovanými viacerými LLM, aby sme pokryli nový typ hrozby. Pri všetkých dátach budeme dodržiavať licenčné podmienky a GDPR.

**2. Anotácia.** Vytvoríme anotačné guidelines s definíciami typov falošných recenzií, hraničných prípadov a neurčitých príkladov. Každú recenziu budú anotovať aspoň dvaja nezávislí anotátori; nezhody vyrieši tretí anotátor. Kvalitu budeme merať Cohenovou kappa a pravidelnými kalibračnými stretnutiami.

**3. Predspracovanie.** Text normalizujeme, identifikujeme jazyk, odstránime duplicity a citlivé údaje. Pre slovenčinu využijeme dostupné nástroje na tokenizáciu, lemmatizáciu a morfologickú analýzu; pri angličtine použijeme štandardné NLP nástroje.

**4. Extrakcia príznakov.** Jazykové príznaky zahŕňajú lexikálnu bohatosť, distribúciu slovných druhov, sentiment, subjektivitu, štylometrické markery a transformer-ové reprezentácie. Behaviorálne príznaky zahŕňajú históriu recenzenta, frekvenciu, burstiness, ratingovú odchýlku a

overený nákup. Grafové príznaky zahŕňajú bipartitný graf recenzent–produkt, ko-recenzné skupiny a miery centrality.

**5. Modelovanie.** Ako baselines použijeme logistickú regresiu, SVM a gradientové boosting. Následne natrénujeme transformer (BERT alebo jeho viacjazyčný variant) a grafovú neurónovú sieť. Hybridný model vznikne early fusion (spoločný vektor príznakov) a late fusion (vážená kombinácia rozhodnutí); porovnáme oba varianty.

**6. Evaluácia.** Použijeme stratifikovanú krížovú validáciu, časové rozdelenie a rozdelenie podľa domén. Sledujeme precision, recall, F1, AUROC, mieru falošných pozitív pri fixnom zachytení a kalibráciu (ECE). Súčasťou je aj testovanie na novom jazyku a na adversariálnych príkladoch.

**7. Vysvetliteľnosť.** Pre globálne vysvetlenie použijeme SHAP a permutation importance, pre lokálne vysvetlenie LIME a attention. Overíme, či vysvetlenia zodpovedajú intuícii moderátorov a či zvyšujú ich dôveru v model.

**8. Pilot.** Prototyp nasadíme v režime tieňového rozhodovania, aby neovplyvňoval reálne rozhodnutia. Zbierame spätnú väzbu moderátorov, meriame čas rozhodovania a mieru falošných pozitív. Výsledky použijeme na finálnu kalibráciu a na správu pre prax.

Etický rámec zahŕňa minimalizáciu osobných údajov, anonymizáciu, informovaný súhlas pri partnerských dátach a nezávislý pohľad na riziko zneužitia detektora na cenzúru legitímnych recenzií.

### 1.6 Predchádzajúce výsledky a kompetencie

Zodpovedný riešiteľ Ing. Ivan Kapustík pôsobí na FIIT STU (Ústav informatiky a softvérového inžinierstva) a dlhodobo sa venuje softvérovému inžinierstvu, práci s dátami a vedeniu študentských projektových tímov (predmet Tímový projekt). Expertízu tímu v oblasti spracovania prirodzeného jazyka a strojového učenia zabezpečí spolupráca so špecialistami fakulty a mladými riešiteľmi. Uvedieme najviac 5 najvýznamnejších výstupov za posledných 5 rokov a najviac 3 projekty, ktoré zodpovedný riešiteľ viedol. Položky sú zoradené od najvýznamnejšej po menej významnú (podľa vyjadrenia Ing. Kapustíka); konkrétne údaje doplníme pred podaním podľa životopisu zodpovedného riešiteľa.

Jeho víziou je budovať výskumný tím zameraný na dôveryhodnú analýzu textu a správania, systematicky rozvíjať expertízu v oblasti vysvetliteľného strojového učenia a vytvárať priestor pre kariérny rast mladých výskumníkov — od semestrálnych projektov cez diplomové práce až po doktorandské štúdium a vlastné grantové projekty.

| # | Najvýznamnejší výstup za posledných 5 rokov (max. 5, od najvýznamnejšieho) | Rok |
|---|---|---|
| V1 | *doplniť názov publikácie/výstupu a jeho význam* | doplniť |
| V2 | *doplniť názov publikácie/výstupu a jeho význam* | doplniť |
| V3 | *doplniť názov publikácie/výstupu a jeho význam* | doplniť |
| V4 | *doplniť názov publikácie/výstupu a jeho význam* | doplniť |
| V5 | *doplniť názov publikácie/výstupu a jeho význam* | doplniť |

| # | Projekt (max. 3, najvýznamnejšie; názov, schéma, roky, rozpočet) | Rola (viedol) | Význam |
|---|---|---|---|
| P1 | *doplniť* | *doplniť* | *doplniť* |
| P2 | *doplniť* | *doplniť* | *doplniť* |
| P3 | *doplniť* | *doplniť* | *doplniť* |

Organizácia disponuje laboratóriami, výpočtovou infraštruktúrou a prístupom k vedeckým databázam. Fakulta má skúsenosti s riešením grantových projektov, s vedením bakalárskych a diplomových prác a s publikovaním v oblasti informatiky. Pre projekt je dôležitá aj medzinárodná spolupráca a možnosť konzultovať výsledky s odborníkmi z praxe.

### 1.7 Zapojenie mladých pracovníkov

Na riešení sa podieľajú štyria študenti druhého stupňa, ktorí tvoria 80 % riešiteľského tímu. Matvii Nosenko sa zameria na NLP a modely strojového učenia, Volodymyr Nedoluha na zber a spracovanie dát, Danylo Nikolenko na backend a API a Rostyslav Mykytiuk na evaluáciu a vizualizáciu výsledkov. Expertízu jednotlivých riešiteľov tvoria kvalifikačné a semestrálne práce v oblasti spracovania prirodzeného jazyka, analýzy dát a softvérového inžinierstva; pred podaním ju doplníme o konkrétne výsledky a skúsenosti. Každý z nich bude mať možnosť publikovať ako spoluautor, zúčastniť sa konferencie a získať praktické skúsenosti s riešením aplikovaného projektu. Plán rozvoja zahŕňa pravidelné odborné semináre, revízie kódu a mentoring zo strany zodpovedného riešiteľa.

## 2 Dopad

### 2.1 Prínosy pre poznanie, aplikovaný výskum a inovácie

Projekt prinesie štyri druhy prínosov. Prvým je otvorený slovensko-anglický dataset a benchmark, ktorý umožní reprodukovateľné porovnávanie metód a podporí ďalší výskum v slovenskom kontexte. Druhým je hybridná metodika, ktorá systematicky meria prínos jazykových, behaviorálnych a grafových príznakov a ukazuje, kedy sa ktorá skupina vyplatí. Tretím je model s vysvetliteľnými výstupmi, ktorý prepája presnosť s dôveryhodnosťou pre moderátorov. Štvrtým je prototyp API a dashboard, ktorý demonštruje použiteľnosť v praxi.

Z hľadiska inovácií ide o novú službu pre prevádzkovateľov platforiem: modulárny detektor, ktorý možno nasadiť ako súčasť moderovacieho procesu alebo ako samostatnú analytickú vrstvu. Riešenie nie je viazané na konkrétnu platformu a jeho architektúra umožňuje rozšírenie o ďalšie jazyky a domény.

### 2.2 Využiteľnosť výsledkov v SR a zahraničí

Na Slovensku môžu výsledky využiť prevádzkovatelia e-shopov a trhovísk, recenzné portály, profesijné asociácie a orgány ochrany spotrebiteľa. V zahraničí je potenciál najmä v krajinách EÚ, kde platí spoločný regulačný rámec pre zavádzajúce recenzie a transparentnosť platforiem. Dataset a metodika sú jazykovo rozšíriteľné, takže ich možno adaptovať na český, poľský alebo maďarský jazyk.

Výsledky budú využiteľné v troch režimoch: (i) offline analýza historických dát pre audit a reporting; (ii) online asistencia moderátorovi s vysvetlením a prioritizáciou podozrivých recenzií; (iii) monitorovanie trendov a nových typov útokov. Každý režim má iné požiadavky na latenciu, vysvetliteľnosť a ochranu údajov, čo projekt zohľadní v návrhu API.

### 2.3 Ekonomický a spoločenský prínos

Falošné recenzie spôsobujú priame straty spotrebiteľom, poškodzujú poctivých predajcov a zvyšujú náklady platforiem na moderovanie. Presnejší a vysvetliteľný detektor môže tieto náklady znížiť, zvýšiť dôveru v recenzie a zlepšiť kvalitu rozhodovania. Prínos je zároveň spoločenský: ochrana spotrebiteľov, transparentnosť a férová súťaž.

Kvantifikácia prínosu bude predmetom pilotu. Budeme sledovať počet odhalených podozrivých recenzií, mieru falošných pozitív, čas moderátora na jedno rozhodnutie a subjektívnu dôveru moderátorov. Ekonomický prínos vyjadríme ako odhad úspory času a zníženia počtu sťažností; pôjde o konzervatívny odhad, nie o marketingové číslo.

### 2.4 Opatrenia na maximalizáciu dopadu a komunikácia

Projekt bude priebežne zverejňovať výsledky formou odborných článkov, preprintov, workshopov a krátkych správ pre prax. Dataset a kód sprístupníme za jasných licenčných podmienok. Pre

prevádzkovateľov pripravíme praktického sprievodcu nasadením a pre regulátorov stručný policy brief. Komunikácia bude prebiehať cez web fakulty, odborné podujatia a partnerské kanály.

Meranie dopadu bude na troch úrovniach: vedeckej (publikácie, citácie, využitie datasetu), technologickej (počet nasadení, latencia, presnosť) a spoločenskej (počet chránených spotrebiteľov, zníženie sťažností). Tieto ukazovatele budeme vyhodnocovať na konci projektu a priebežne na míľnikoch.

# 3 Implementácia

## 3.1 Projektový plán, pracovné balíky a výstupy

Projekt je rozdelený na sedem pracovných balíkov, ktoré sa čiastočne prekrývajú. Každý balík má zodpovedného riešiteľa, výstupy a míľnik.

| WP | Názov a obsah | Výstup | Mesiace |
|---|---|---|---|
| WP1 | Manažment, koordinácia, reporting, riadenie rizík | plán, správy | 1–36 |
| WP2 | Zber, anotácia a sprístupnenie dát | dataset, guidelines | 1–12 |
| WP3 | Jazykové modely a baseline | model, evaluácia | 7–18 |
| WP4 | Behaviorálne a grafové modely | model, evaluácia | 13–24 |
| WP5 | Hybridný model a vysvetliteľnosť | prototyp | 19–30 |
| WP6 | Pilotné overenie a evaluácia | pilotná správa | 25–36 |
| WP7 | Diseminácia a komunikácia | publikácie, web | 1–36 |

Výstupy sú navrhnuté tak, aby na seba nadväzovali: dataset a guidelines sú predpokladom pre modely, modely pre hybridný prototyp a prototyp pre pilot. Každý výstup má jasného vlastníka a kontrolu kvality.

## 3.2 Harmonogram a míľniky

| Míľnik | Popis | Termín |
|---|---|---|
| M6 | Schválená metodika anotácie a etický rámec | 06/2027 |
| M12 | Dataset SK/EN s minimálne 15 000 recenziami | 12/2027 |
| M18 | Jazykový model a prvá publikácia | 06/2028 |
| M24 | Behaviorálny a grafový model | 12/2028 |
| M30 | Hybridný model a prototyp API | 06/2029 |
| M36 | Pilotná správa, finálne vyhodnotenie a druhá publikácia | 12/2029 |

## 3.3 Projektový manažment

Projekt bude riadený zodpovedným riešiteľom, ktorý rozhoduje o prioritách, rozpočte a personálnych otázkach. Operatívne riadenie zabezpečí projektový koordinátor z tímu. Budeme používať pravidelné týždenné stretnutia, mesačné revízie a štvrťročné hodnotiace správy. Úlohy budeme evidovať v Jira a kód v Git repozitári; každá zmena bude mať issue key a code review.

Kontrolné mechanizmy zahŕňajú: (i) kontrolu kvality dát pred uzamknutím datasetu; (ii) reprodukovateľnosť experimentov cez fixné seeds a verzovanie; (iii) nezávislú revíziu evaluačného protokolu; (iv) etickú kontrolu pred prácou s partnerskými dátami. Riziká budeme priebežne aktualizovať v registri rizík a na mesačných revíziách.

| Riziko | Dopad | Zmiernenie |
|---|---|---|
| Obmedzený prístup k dátam | oneskorenie WP2 | verejné datasety, syntetické dáta, včasné rokovanie s partnermi |
| Nízka kvalita anotácie | skreslené výsledky | guidelines, viac anotátorov, kappa, kalibrácia |
| Nezvyknutý nepomer tried | nízky recall | cost-sensitive learning, resampling, kalibrácia |
| Posun distribúcie a LLM drift | pokles presnosti | časové testy, priebežné učenie, adversariálne testovanie |
| GDPR a citlivé údaje | právne riziko | minimalizácia, anonymizácia, súhlasy, etická kontrola |
| Odchod člena tímu | strata znalostí | dokumentácia, párové programovanie, zastupiteľnosť |
| Závislosť na partnerovi | oneskorenie pilotu | viac partnerov, offline pilot, jasné zmluvy |

### 3.4 Riziká implementácie a ich zmiernenie

### 3.5 Rozpočet

Rozpočet vychádza z 36 mesiacov riešenia a je detailne rozpísaný vo formulári VV-C. Celkové náklady sú 300 000 EUR, z toho 268 000 EUR z APVV a 32 000 EUR zo spolufinancovania. Najväčšiu časť tvoria mzdové náklady a odvody, nasledujú služby, cestovné a nepriame náklady.

| Kategória | Spolu (EUR) |
|---|---|
| Mzdové náklady a ostatné osobné náklady | 140 000 |
| Zdravotné a sociálne poistenie | 49 000 |
| Cestovné náklady | 15 000 |
| Materiál | 12 000 |
| Služby | 30 000 |
| Energie, vodné, stočné, komunikácie | 4 000 |
| Náklady na popularizáciu | 8 000 |
| Bežné nepriame náklady | 42 000 |
| Celkové náklady | 300 000 |

Rozpočet je primeraný cieľom: najviac prostriedkov smeruje na ľudskú prácu (anotácia, modelovanie, evaluácia), ktorá je pre projekt kritická. Cestovné náklady pokrývajú konferencie a stretnutia s partnermi, služby zahŕňajú cloudový výpočet a právne poradenstvo. Pred finálnym podaním rozpočet preveríme podľa taríf organizácie a podmienok výzvy.

### 3.6 Infraštruktúra

FIIT STU disponuje výpočtovou infraštruktúrou, laboratóriami a prístupom k vedeckým databázam. Pre projekt využijeme servery s GPU pre trénovanie transformerov, úložisko pre datasety a zabezpečené prostredie pre prácu s citlivými dátami. Personálnu infraštruktúru tvoria štyria študenti, zodpovedný riešiteľ a administratívna podpora fakulty. V prípade potreby doplníme cloudové zdroje z rozpočtu projektu.

## Literatúra


[1] Yuexin Zhao, Siyi Tang, Hongyu Zhang, and Long Lyu. AI vs. human: A large-scale analysis of AI-generated fake reviews, human-generated fake reviews and authentic reviews. *Journal of Retailing and Consumer Services*, 87:104400, 2025.

[2] Nitin Jindal and Bing Liu. Opinion spam and analysis. In *Proceedings of the 2008 International Conference on Web Search and Data Mining (WSDM)*, pages 219–230. ACM, 2008.

[3] Myle Ott, Yejin Choi, Claire Cardie, and Jeffrey T. Hancock. Finding deceptive opinion spam by any stretch of the imagination. In *Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics*, pages 309–319, 2011.

[4] Michael Luca and Georgios Zervas. Fake it till you make it: Reputation, competition, and Yelp review fraud. *Management Science*, 62(12):3412–3427, 2016.

[5] Arjun Mukherjee, Vivek Venkataraman, Bing Liu, and Natalie Glance. What Yelp fake review filter might be doing? In *Proceedings of the International AAAI Conference on Web and Social Media*, volume 7, pages 409–418, 2013.

[6] Arjun Mukherjee, Bing Liu, and Natalie Glance. Spotting fake reviewer groups in consumer reviews. In *Proceedings of the 21st International Conference on World Wide Web (WWW)*, pages 191–200. ACM, 2012.

[7] Shebuti Rayana and Leman Akoglu. Collective opinion spam detection: Bridging review networks and metadata. In *Proceedings of the 21st ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pages 985–994. ACM, 2015.

[8] Michael Crawford, Taghi M. Khoshgoftaar, Joseph D. Prusa, Aaron N. Richter, and Hamzah Al Najada. Survey of review spam detection using machine learning techniques. *Journal of Big Data*, 2(1):23, 2015.

[9] Atefeh Heydari, Mohammad Ali Tavakoli, Naomie Salim, and Zahra Heydari. Detection of review spam: A survey. *Expert Systems with Applications*, 42(7):3634–3642, 2015.

[10] Rodrigo Barbado, Oscar Araque, and Carlos A. Iglesias. A framework for fake review detection in online consumer electronics retailers. *Information Processing & Management*, 56(4):1234–1244, 2019.

[11] Jiwei Li, Myle Ott, Claire Cardie, and Eduard Hovy. Towards a general rule for identifying deceptive opinion spam. In *Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1566–1576. Association for Computational Linguistics, 2014.