VV-F — Vecný zámer projektu

Záväzná osnova pre aplikovaný výskum a vývoj

Detekcia falošných online recenzií na základe jazykových a behaviorálnych príznakov

Detection of Fake Online Reviews Based on Linguistic and Behavioral Features

Akronym:	FAKERADAR
Evidenčné číslo:	Zatiaľ nepridelené (študentský návrh)
Žiadateľ:	Slovenská technická univerzita v Bratislave, Fakulta informatiky a informačných technológií
Zodpovedný riešiteľ:	Ing. Ivan Kapustík
Dátum:	01.11.2026
Obdobie riešenia:	01/2027 – 12/2029

Dokument je modelovým návrhom v rozsahu približne 50–60 % očakávanej finálnej verzie. Personálne a ekonomické údaje označené ako „(doplní sa)“ alebo „modelový údaj“ sa doplnia vo finálnej verzii.

1 Excelentnosť

1.1 Projektový zámer a aplikačná úroveň

Online recenzie sú jedným z najvplyvnejších informačných kanálov v elektronickom obchode. Spotrebitelia na ich základe porovnávajú produkty, predajcov a ceny, podniky zase budujú reputáciu a konkurenčnú výhodu. Táto ekonomická hodnota vytvára motiváciu manipulovať recenzným priestorom prostredníctvom platených recenzentov, konkurenčných útokov, koordinovaných skupín účtov alebo automatizovaných nástrojov. Falošné recenzie preto poškodzujú spotrebiteľov, znižujú dôveryhodnosť platforiem a narúšajú férovú súťaž.

Projekt reaguje na medzeru medzi akademickými detektormi a potrebami praxe. Existujúce riešenia sú prevažne anglocentrické, založené na povrchových jazykových príznakoch a v podmienkach generatívnych modelov strácajú spoľahlivosť. Prevádzkovatelia platforiem zároveň potrebujú nielen presný, ale aj vysvetliteľný nástroj, ktorý dokáže rozhodnutie o označení recenzie zdôvodniť a ktorý je možné prevádzkovať bez neprimeraného zásahu do súkromia používateľov.

Projekt priamo nadväzuje na schválené zameranie, ktoré porovnáva jazykové a behaviorálne príznaky: tie tvoria jadro projektu a ich prínos sa bude merať samostatne aj v kombinácii. Grafové príznaky, vrstvu vysvetlenia a detekciu recenzií generovaných LLM berieme ako rozšírenia tohto jadra. Projekt preto vyvinie hybridný detektor falošných recenzií, ktorý spája jazykové, behaviorálne a grafové príznaky, doplní ho o vrstvu vysvetlenia a overí v pilotnej prevádzke. Výstupom bude otvorený slovensko-anglický anotovaný dataset, metodika anotácie a hodnotenia, referenčný model, prototyp API a správa pre prax. Ako pracovný návrh uvažujeme posun TRL 3→TRL 6: od overenia konceptu k prototypu demonštrovanému v relevantnom prostredí. Toto zaradenie je predbežné a tím ho musí potvrdiť podľa skutočnej východiskovej zrelosti riešenia a definícií TRL.

1.2 Aktuálnosť a originalita

Aktuálnosť témy je daná tromi súbežnými trendmi. Prvým je rast elektronického obchodu a závislosti spotrebiteľov od recenzií. Druhým je dostupnosť veľkých jazykových modelov, ktoré dokážu generovať plynulé a štylisticky presvedčivé recenzie v takmer neobmedzenom množstve [1]. Tretím je regulácia: európsky rámec zakazuje zavádzajúce recenzie a posilňuje transparentnosť platforiem, čím vzniká dopyt po obhájiteľných nástrojoch moderovania.

Originalita projektu spočíva v piatich prvkoch. (i) Vytvoríme otvorený slovensko-anglický benchmark pre detekciu falošných recenzií s viacnásobnou anotáciou; prvenstvo benchmarku budeme tvrdiť až po systematickom preskúmaní existujúcich zdrojov. (ii) Spojíme textové, behaviorálne a grafové príznaky v jednom modeli a systematicky porovnáme ich prínos. (iii) Budeme explicitne modelovať recenzie generované LLM, nielen ľuďmi písaný spam. (iv) Vysvetliteľnosť bude rovnocenným cieľom, nie dodatočnou funkciou. (v) Výstupy budú otvorené a reprodukovateľné, ak to umožnia licencie a podmienky zdrojových dát.

Nejde teda o ďalší izolovaný klasifikátor, ale o metodiku a nástroj, ktorý prepája výskum s moderovaním v praxi. Práve kombinácia dát, hybridného modelovania a vysvetliteľnosti vytvára priestor na originálny príspevok v slovenskom aj medzinárodnom kontexte.

1.3 Stav poznania a vedecké základy

Výskum detekcie falošných recenzií sa rozvíja od práce Jindala a Liu [2], ktorí vymedzili taxonómiu recenzného spamu a ukázali, že duplicitné texty sú silným indikátorom manipulácie. Ott a kol. [3] vytvorili prvý štandardizovaný dataset klamlivých recenzií a demonštrovali, že n-gramy a psycholingvistické lexikóny prekonávajú ľudských posudzovateľov. Ich práca zároveň upozornila na metodologický problém: pri autenticky pôsobiacich textoch sa klasifikátor môže učiť idiosynkrázie konkrétnych autorov namiesto všeobecného pojmu falošnosti.

Ekonomické motivácie analyzovali Luca a Zervas [4], ktorí dokumentovali vzťah medzi reputáciou podniku a objednávaním falošných pozitívnych recenzií. Mukherjee a kol. [5] ukázali, že behaviorálne príznaky môžu byť informatívnejšie než samotný text. Samostatnú líniu predstavujú práce o koordinovaných skupinách a recenzných sieťach: Mukherjee a kol. [6] odhaľovali falošné recenzentské skupiny, Rayana a Akoglu [7] spojili recenzie, recenzentov a produkty do jednej siete a využili šírenie podozrenia medzi prepojenými entitami.

Prehľadové práce [8] a [9] zjednotili terminológiu a rozdelili prístupy podľa typu príznakov a úrovne rozhodovania. Barbado a kol. [10] overili aplikačný rozmer na doméne spotrebnej elektroniky a Li a kol. [11] ukázali, že existujú relatívne univerzálne, ľudsky interpretovateľné pravidlá prekračujúce hranice datasetu. Zhao a kol. [1] napokon dokumentovali, že AI-generované recenzie sú plynulejšie a štylisticky konzistentnejšie než ľudské, čo oslabuje čisto textové detektory.

Napriek tomuto pokroku zostávajú medzery, na ktoré projekt reaguje. Chýba otvorený slovensko-anglický dataset, systematické porovnanie jazykových a behaviorálnych príznakov v podmienkach LLM, prakticky použiteľný hybridný detektor s vysvetliteľnými výstupmi a metodika hodnotenia, ktorá zohľadňuje časový a doménový posun. Vedecké základy projektu preto tvoria štyri oblasti: spracovanie prirodzeného jazyka a štylometria, behaviorálna analýza a dolovanie v grafoch, strojové učenie s dôrazom na kalibráciu a generalizáciu a nakoniec výskum vysvetliteľnosti a používateľskej dôvery.

1.4 Ciele projektu

Ciele sú formulované merateľne a viažu sa na konkrétne výstupy a termíny.

#	Cieľ	Ukazovateľ	Termín
O1	Vytvoriť otvorený slovensko-anglický anotovaný dataset	pracovný cieľ: 15 000 recenzií; $\kappa \geq 0{,}7$	M12
O2	Vyvinúť jazykový model	F1 $\geq$ 0,80 v rámci domény	M18
O3	Vyvinúť behaviorálny a grafový model	F1 $\geq$ 0,75; odhalenie skupín	M24
O4	Skonštruovať hybridný model	F1 $\geq$ 0,85 in-domain; $\geq$ 0,75 cross-domain	M30
O5	Overiť prototyp v relevantnom prostredí	partnerský pilot, ak sa zabezpečí prístup; inak offline test; merať vysvetliteľnosť a latenciu	M36

Ciele sú pracovné plánovacie ciele tejto predbežnej verzie, nie výsledky už vykonaných experimentov ani čísla predpísané stránkou MIP/APVV. Cieľ 15 000 je návrhový rozsah pre dvojjazyčný dataset (orientačne polovica na každý jazyk); jeho realizovateľnosť sa preverí po audite dostupných dát a anotačnej kapacity v M6. Hranica $\kappa \geq 0{,}7$ je orientačný cieľ zhody anotátorov; interpretácia kappa závisí od domény a rozdelenia tried, pričom Landis a Koch uvádzajú interval 0,61–0,80 ako „substantial agreement“ [12]. Ciele F1 (0,80 pre jazykový model, 0,75 pre behaviorálny/grafový a 0,85 pre hybridný model v rámci domény; 0,75 pri prenose) sú počiatočné akceptačné prahy zvolené tímom na porovnanie modelov, nie garancia výsledku; po vytvorení baseline v M6 ich tím prehodnotí a zdokumentuje. Všetky míľniky M6–M36 sa počítajú od navrhnutého začiatku 01/2027; dátumy a rozsah pilotu zostávajú závislé od prístupu k dátam a partnerom.

Pri návrhovom cieli 15 000 záznamov plánujeme ako pracovnú možnosť stratifikované rozdelenie 70 / 15 / 15 na tréning, validáciu a test (10 500 / 2 250 / 2 250 záznamov); nejde o požiadavku webu ani o už získané dáta. Rozdelenie treba upraviť podľa dostupnosti a pomeru tried v oboch jazykoch. Prahy F1 sú predbežné ciele tímu, ktoré sa porovnajú s baseline na časovo a doménovo oddelených testovacích množinách; ak pilotné výsledky ukážu, že nie sú realistické, vo finálnej verzii sa zdôvodnene upravia.

1.5 Metodológia

Metodológia je navrhnutá ako sekvencia ôsmich krokov, ktoré sa čiastočne prekrývajú.

1. Zber dát. Využijeme verejné datasety (napr. Ott a kol. [3]), verejne dostupné recenzie z platforiem a dátové zdroje partnerských organizácií. Doplníme ich syntetickými recenziami generovanými viacerými LLM, aby sme pokryli nový typ hrozby. Pri všetkých dátach budeme dodržiavať licenčné podmienky a GDPR.

2. Anotácia. Vytvoríme anotačné guidelines s definíciami typov falošných recenzií, hraničných prípadov a neurčitých príkladov. Každú recenziu budú anotovať aspoň dvaja nezávislí anotátori; nezhody vyrieši tretí anotátor. Kvalitu budeme merať Cohenovou kappa a pravidelnými kalibračnými stretnutiami.

3. Predspracovanie. Text normalizujeme, identifikujeme jazyk, odstránime duplicity a citlivé údaje. Pre slovenčinu využijeme dostupné nástroje na tokenizáciu, lemmatizáciu a morfologickú analýzu; pri angličtine použijeme štandardné NLP nástroje.

4. Extrakcia príznakov. Jazykové príznaky zahŕňajú lexikálnu bohatosť, distribúciu slovných druhov, sentiment, subjektivitu, štylometrické markery a transformer-ové reprezentácie. Behaviorálne príznaky zahŕňajú históriu recenzenta, frekvenciu, burstiness, ratingovú odchýlku a overený nákup. Grafové príznaky zahŕňajú bipartitný graf recenzent–produkt, ko-recenzné skupiny a miery centrality.

5. Modelovanie. Ako baselines použijeme logistickú regresiu, SVM a gradientové boosting. Následne natrénujeme transformer (BERT alebo jeho viacjazyčný variant) a grafovú neurónovú sieť. Hybridný model vznikne early fusion (spoločný vektor príznakov) a late fusion (vážená kombinácia rozhodnutí); porovnáme oba varianty.

6. Evaluácia. Použijeme stratifikovanú krížovú validáciu, časové rozdelenie a rozdelenie podľa domén. Sledujeme precision, recall, F1, AUROC, mieru falošných pozitív pri fixnom zachytení a kalibráciu (ECE). Súčasťou je aj testovanie na novom jazyku a na adversariálnych príkladoch.

7. Vysvetliteľnosť. Pre globálne vysvetlenie použijeme SHAP a permutation importance, pre lokálne vysvetlenie LIME a attention. Overíme, či vysvetlenia zodpovedajú intuícii moderátorov a či zvyšujú ich dôveru v model.

8. Pilot. Prototyp nasadíme v režime tieňového rozhodovania, aby neovplyvňoval reálne rozhodnutia. Zbierame spätnú väzbu moderátorov, meriame čas rozhodovania a mieru falošných pozitív. Výsledky použijeme na finálnu kalibráciu a na správu pre prax.

Etický rámec zahŕňa minimalizáciu osobných údajov, anonymizáciu, informovaný súhlas pri partnerských dátach a nezávislý pohľad na riziko zneužitia detektora na cenzúru legitímnych recenzií.

1.6 Predchádzajúce výsledky a kompetencie

Zodpovedný riešiteľ Ing. Ivan Kapustík pôsobí na FIIT STU (Ústav informatiky a softvérového inžinierstva) a dlhodobo sa venuje softvérovému inžinierstvu, práci s dátami a vedeniu študentských projektových tímov (predmet Tímový projekt). Expertízu tímu v oblasti spracovania prirodzeného jazyka a strojového učenia zabezpečí spolupráca so špecialistami fakulty a mladými riešiteľmi. Uvedieme najviac 5 najvýznamnejších výstupov za posledných 5 rokov a najviac 3 projekty, ktoré zodpovedný riešiteľ viedol; projekty môžu byť ľubovoľného typu, nielen grantové. Vyberáme podľa významnosti výstupu, pričom sa zoradia od najvýznamnejšej po menej významnú položku. V predbežnej verzii sú tabuľky zástupné; konkrétne údaje doplníme vo finálnej verzii podľa životopisu zodpovedného riešiteľa.

Jeho víziou je budovať výskumný tím zameraný na dôveryhodnú analýzu textu a správania,

systematicky rozvíjať expertízu v oblasti vysvetliteľného strojového učenia a vytvárať priestor pre kariérny rast mladých výskumníkov — od semestrálnych projektov cez diplomové práce až po doktorandské štúdium a vlastné grantové projekty.

#	Najvýznamnejší výstup za posledných 5 rokov (max. 5, od najvýznamnejšieho)	Rok
V1	—	—
V2	—	—
V3	—	—
V4	—	—
V5	—	—

Poznámka: zástupné riadky — konkrétne výstupy zodpovedného riešiteľa sa doplnia vo finálnej verzii.

#	Projekt (max. 3, najvýznamnejšie; názov, schéma, roky, rozpočet)	Rola (viedol)	Význam
P1	—	—	—
P2	—	—	—
P3	—	—	—

Poznámka: zástupné riadky — projekty vedené zodpovedným riešiteľom sa doplnia vo finálnej verzii.

Organizácia disponuje laboratóriami, výpočtovou infraštruktúrou a prístupom k vedeckým databázam. Fakulta má skúsenosti s riešením grantových projektov, s vedením bakalárskych a diplomových prác a s publikovaním v oblasti informatiky. Pre projekt je dôležitá aj medzinárodná spolupráca a možnosť konzultovať výsledky s odborníkmi z praxe.

1.7 Zapojenie mladých pracovníkov

Štyria študenti sú riešiteľmi prvého stupňa VŠ (Bc.); tvoria 80 % z piatich uvedených riešiteľov. Tento podiel vyjadruje zastúpenie študentov v tíme, nie potvrdené percento mladých pracovníkov; vekové zaradenie treba potvrdiť po doplnení dátumov narodenia. Matvii Nosenko sa zameria na NLP a modely strojového učenia, Volodymyr Nedoluha na zber a spracovanie dát, Danylo Nikolenko na backend a API a Rostyslav Mykytiuk na evaluáciu a vizualizáciu výsledkov. Konkrétnu odbornú expertízu jednotlivých študentov doplníme podľa ich životopisov/semestrálnych prác. Každý z nich bude mať možnosť publikovať ako spoluautor, zúčastniť sa konferencie a získať praktické skúsenosti s riešením aplikovaného projektu. Plán rozvoja zahŕňa pravidelné odborné semináre, revízie kódu a mentoring zo strany zodpovedného riešiteľa.

2 Dopad

2.1 Prínosy pre poznanie, aplikovaný výskum a inovácie

Projekt prinesie štyri druhy prínosov. Prvým je otvorený slovensko-anglický dataset a benchmark, ktorý umožní reprodukovateľné porovnávanie metód a podporí ďalší výskum v slovenskom kontexte. Druhým je hybridná metodika, ktorá systematicky meria prínos jazykových, behaviorálnych a grafových príznakov a ukazuje, kedy sa ktorá skupina vyplatí. Tretím je model s vysvetliteľnými výstupmi, ktorý prepája presnosť s dôveryhodnosťou pre moderátorov. Štvrtým je prototyp API a dashboard, ktorý demonštruje použiteľnosť v praxi.

Z hľadiska inovácií ide o novú službu pre prevádzkovateľov platforiem: modulárny detektor, ktorý možno nasadiť ako súčasť moderovacieho procesu alebo ako samostatnú analytickú vrstvu. Riešenie nie je viazané na konkrétnu platformu a jeho architektúra umožňuje rozšírenie o ďalšie jazyky a domény.

2.2 Využiteľnosť výsledkov v SR a zahraničí

Na Slovensku môžu výsledky využiť prevádzkovatelia e-shopov a trhovísk, recenzné portály, profesijné asociácie a orgány ochrany spotrebiteľa. V zahraničí je potenciál najmä v krajinách EÚ, kde platí spoločný regulačný rámec pre zavádzajúce recenzie a transparentnosť platforiem. Dataset a metodika sú jazykovo rozšíriteľné, takže ich možno adaptovať na český, poľský alebo maďarský jazyk.

Výsledky budú využiteľné v troch režimoch: (i) offline analýza historických dát pre audit a reporting; (ii) online asistencia moderátorovi s vysvetlením a prioritizáciou podozrivých recenzií; (iii) monitorovanie trendov a nových typov útokov. Každý režim má iné požiadavky na latenciu, vysvetliteľnosť a ochranu údajov, čo projekt zohľadní v návrhu API.

2.3 Ekonomický a spoločenský prínos

Falošné recenzie spôsobujú priame straty spotrebiteľom, poškodzujú poctivých predajcov a zvyšujú náklady platforiem na moderovanie. Presnejší a vysvetliteľný detektor môže tieto náklady znížiť, zvýšiť dôveru v recenzie a zlepšiť kvalitu rozhodovania. Prínos je zároveň spoločenský: ochrana spotrebiteľov, transparentnosť a férová súťaž.

Kvantifikácia prínosu bude predmetom pilotu. Budeme sledovať počet odhalených podozrivých recenzií, mieru falošných pozitív, čas moderátora na jedno rozhodnutie a subjektívnu dôveru moderátorov. Ekonomický prínos vyjadríme ako odhad úspory času a zníženia počtu sťažností; pôjde o konzervatívny odhad, nie o marketingové číslo.

2.4 Opatrenia na maximalizáciu dopadu a komunikácia

Projekt bude priebežne zverejňovať výsledky formou odborných článkov, preprintov, workshopov a krátkych správ pre prax. Dataset a kód sprístupníme za jasných licenčných podmienok. Pre prevádzkovateľov pripravíme praktického sprievodcu nasadením a pre regulátorov stručný policy brief. Komunikácia bude prebiehať cez web fakulty, odborné podujatia a partnerské kanály.

Meranie dopadu bude na troch úrovniach: vedeckej (publikácie, citácie, využitie datasetu), technologickej (počet nasadení, latencia, presnosť) a spoločenskej (počet chránených spotrebiteľov, zníženie sťažností). Tieto ukazovatele budeme vyhodnocovať na konci projektu a priebežne na míľnikoch.

3 Implementácia

3.1 Projektový plán, pracovné balíky a výstupy

Projekt je rozdelený na sedem pracovných balíkov, ktoré sa čiastočne prekrývajú. Každý balík má výstup a míľnik; zodpovednosti za balíky sa priradia podľa odbornej špecializácie členov tímu (bod 1.7) a pri štarte projektu sa spresnia.

WP	Názov a obsah	Výstup	Mesiace
WP1	Manažment, koordinácia, reporting, riadenie rizík	plán, správy	1–36
WP2	Zber, anotácia a sprístupnenie dát	dataset, guidelines	1–12
WP3	Jazykové modely a baseline	model, evaluácia	7–18
WP4	Behaviorálne a grafové modely	model, evaluácia	13–24
WP5	Hybridný model a vysvetliteľnosť	prototyp	19–30
WP6	Pilotné overenie a evaluácia	pilotná správa	25–36
WP7	Diseminácia a komunikácia	publikácie, web	1–36

Výstupy sú navrhnuté tak, aby na seba nadväzovali: dataset a guidelines sú predpokladom pre modely, modely pre hybridný prototyp a prototyp pre pilot. Každý výstup bude mať kontrolu

kvality podľa postupu uvedeného v bode 3.3.

3.2 Harmonogram a míľniky

Míľnik	Popis	Termín
M6	Schválená metodika anotácie a etický rámec	06/2027
M12	Dataset SK/EN s minimálne 15 000 recenziami	12/2027
M18	Jazykový model a prvá publikácia	06/2028
M24	Behaviorálny a grafový model	12/2028
M30	Hybridný model a prototyp API	06/2029
M36	Pilotná správa, finálne vyhodnotenie a druhá publikácia	12/2029

3.3 Projektový manažment

Projekt bude riadený zodpovedným riešiteľom, ktorý rozhoduje o prioritách, rozpočte a personálnych otázkach. Operatívne riadenie zabezpečí projektový koordinátor z tímu. Budeme používať pravidelné týždenné stretnutia, mesačné revízie a štvrťročné hodnotiace správy. Úlohy budeme evidovať v Jira a kód v Git repozitári; každá zmena bude mať issue key a code review.

Kontrolné mechanizmy zahŕňajú: (i) kontrolu kvality dát pred uzamknutím datasetu; (ii) reprodukovateľnosť experimentov cez fixné seeds a verzovanie; (iii) nezávislú revíziu evaluačného protokolu; (iv) etickú kontrolu pred prácou s partnerskými dátami. Riziká budeme priebežne aktualizovať v registri rizík a na mesačných revíziách.

3.4 Riziká implementácie a ich zmiernenie

Riziko	Dopad	Zmiernenie
Obmedzený prístup k dátam	oneskorenie WP2	verejné datasety, syntetické dáta, včasné rokovanie s partnermi
Nízka kvalita anotácie	skreslené výsledky	guidelines, viac anotátorov, kappa, kalibrácia
Nezvyknutý nepomer tried	nízky recall	cost-sensitive learning, resampling, kalibrácia
Posun distribúcie a LLM drift	pokles presnosti	časové testy, priebežné učenie, adversariálne testovanie
GDPR a citlivé údaje	právne riziko	minimalizácia, anonymizácia, súhlasy, etická kontrola
Odchod člena tímu	strata znalostí	dokumentácia, párové programovanie, zastupiteľnosť
Závislosť na partnerovi	oneskorenie pilotu	viac partnerov, offline pilot, jasné zmluvy

3.5 Rozpočet

Rozpočet je modelový výpočet pre študentský projekt v predmete MIP; nejde o skutočný grant ani o schválený rozpočet FIIT. Celkové náklady sú 86 160 EUR bez spolufinancovania. Mzdy sú počítané z predpokladaných hodín (PI 600 h/rok × 22 EUR/h hrubo; štyria študenti 4 × 100 h/rok × 10 EUR/h hrubo) a odvody sú 35 % miezd. Najväčšiu časť tvoria mzdy a odvody, nasledujú služby, cestovné a materiál.

Rozdelenie medzi roky je rovnomerné: 28 720 EUR ročne. Položky na cestovné, materiál, služby a popularizáciu sú odhady bez potvrdených ponúk. Pred finálnou verziou treba overiť hodiny a sadzby.

Kategória	Spolu (EUR)
Mzdové náklady a ostatné osobné náklady	51 600
Zdravotné a sociálne poistenie	18 060
Cestovné náklady	3 000
Materiál	3 000
Služby	6 000
Energie, vodné, stočné, komunikácie	1 500
Náklady na popularizáciu	3 000
Bežné nepriame náklady	0
Celkové náklady	86 160

3.6 Infraštruktúra

FIIT STU disponuje výpočtovou infraštruktúrou, laboratóriami a prístupom k vedeckým databázam. Pre projekt využijeme servery s GPU pre trénovanie transformerov, úložisko pre datasety a zabezpečené prostredie pre prácu s citlivými dátami. Personálnu infraštruktúru tvoria štyria študenti, zodpovedný riešiteľ a administratívna podpora fakulty. V prípade potreby doplníme cloudové zdroje z rozpočtu projektu.

Literatúra

[1] Yuexin Zhao, Siyi Tang, Hongyu Zhang, and Long Lyu. AI vs. human: A large-scale analysis of AI-generated fake reviews, human-generated fake reviews and authentic reviews. *Journal of Retailing and Consumer Services*, 87:104400, 2025.

[2] Nitin Jindal and Bing Liu. Opinion spam and analysis. In *Proceedings of the 2008 International Conference on Web Search and Data Mining (WSDM)*, pages 219–230. ACM, 2008.

[3] Myle Ott, Yejin Choi, Claire Cardie, and Jeffrey T. Hancock. Finding deceptive opinion spam by any stretch of the imagination. In *Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics*, pages 309–319, 2011.

[4] Michael Luca and Georgios Zervas. Fake it till you make it: Reputation, competition, and Yelp review fraud. *Management Science*, 62(12):3412–3427, 2016.

[5] Arjun Mukherjee, Vivek Venkataraman, Bing Liu, and Natalie Glance. What Yelp fake review filter might be doing? In *Proceedings of the International AAAI Conference on Web and Social Media*, volume 7, pages 409–418, 2013.

[6] Arjun Mukherjee, Bing Liu, and Natalie Glance. Spotting fake reviewer groups in consumer reviews. In *Proceedings of the 21st International Conference on World Wide Web (WWW)*, pages 191–200. ACM, 2012.

[7] Shebuti Rayana and Leman Akoglu. Collective opinion spam detection: Bridging review networks and metadata. In *Proceedings of the 21st ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pages 985–994. ACM, 2015.

[8] Michael Crawford, Taghi M. Khoshgoftaar, Joseph D. Prusa, Aaron N. Richter, and Hamzah Al Najada. Survey of review spam detection using machine learning techniques. *Journal of Big Data*, 2(1):23, 2015.

[9] Atefeh Heydari, Mohammad Ali Tavakoli, Naomie Salim, and Zahra Heydari. Detection of review spam: A survey. *Expert Systems with Applications*, 42(7):3634–3642, 2015.

[10] Rodrigo Barbado, Oscar Araque, and Carlos A. Iglesias. A framework for fake review detection in online consumer electronics retailers. *Information Processing & Management*, 56(4):1234–1244, 2019.

[11] Jiwei Li, Myle Ott, Claire Cardie, and Eduard Hovy. Towards a general rule for identifying deceptive opinion spam. In *Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1566–1576. Association for Computational Linguistics, 2014.

[12] J. Richard Landis and Gary G. Koch. The measurement of observer agreement for categorical data. *Biometrics*, 33(1):159–174, 1977.